

MÉTODOS NUMÉRICOS

WRSO 2008

Ejemplo: Cálculo de e^x con la serie de Taylor

$$e^x = \sum_{n=0}^{+\infty} \frac{x^n}{n!} = 1 + x + \frac{x^2}{2} + \frac{x^3}{3!} + \dots + \frac{x^n}{n!} + \dots$$

Al sumando los términos, obteniendo una suma parcial S , matemáticamente siempre agrego algo a la suma, pero en la PC que los números están representados en punto flotante llega un momento en el cual los términos que agrego son tan pequeños que no varían la suma, lo cual la hace finita.

Programa: $S=1;$

$i=1;$

$t = \frac{x}{i};$ *distinto*

while ($S+t \neq S$)

$S = S+t;$

$i = i+1;$

$t = t \cdot \frac{x}{i};$

end;

$$\left. \begin{array}{l} t_1 = \frac{x}{1} \\ t_2 = \frac{x}{1} \cdot \frac{x}{2} = \frac{x^2}{2} \end{array} \right\}$$

$$t_3 = \frac{x^2}{2} \cdot \frac{x}{3} = \frac{x^3}{3!}$$

Se tiene que la expresión $S+t$ va a ser igual a S para t suficientemente pequeño.

Miremos los resultados:

Al correr el prog. $\exp(x)$ dif relativa.

$x = 8$	$2,9810 \cdot 10^3$	$2,9810 \cdot 10^3$	$1,5 \cdot 10^{-16}$
$x = 32$	$7,8963 \cdot 10^{13}$	$7,8963 \cdot 10^{13}$	$-9,9 \cdot 10^{-16}$
$x = -15$	$3,0591 \cdot 10^{-7}$	$3,0590 \cdot 10^{-7}$	$-2,2 \cdot 10^{-5}$
$x = -21$	$-3,16 \cdot 10^{-9}$	$7,58 \cdot 10^{-10}$	
$x = -38$	$-0,1$	absurdo	

¿Cómo puedo resolver este problema?

Si $x \geq 0 \rightarrow$ aplico el programa

Si $x < 0 \rightarrow$ aplico el programa con $x' = -x$
valor final = $1/5$

$$e^x = e^{-x'} = \frac{1}{e^{x'}}$$

Ejemplo: Sistema lineal de 2 ecuaciones
(Problema mal condicionado)

$$\begin{cases} 0,780x + 0,563y = 0,217 \\ 0,457x + 0,330y = 0,127 \end{cases}$$

escalizando:

$$\text{la } 2^{\text{a}} \text{ ecuación} - \frac{0,457}{0,780} \cdot \text{la } 1^{\text{a}} \text{ ecuación}$$

$$(0,330 - \frac{0,457}{0,780} \cdot 0,563)y = 0,127 - \frac{0,457}{0,780} \cdot 0,217$$

$$8,2 \cdot 10^{-5}y = -1,62 \cdot 10^{-4}$$


$$y^* = -1,98 \rightarrow x^* = 1,71$$

Solución exacta $\begin{cases} x = 1 \\ y = -1 \end{cases}$

llegué a una solución que no tiene nada que ver con la solución exacta. Si sustituyo x^* e y^* en las ecuaciones: $0,78 \cdot 1,71 + 0,563(-1,98) - 0,217 = 0,00206$

$$0,457 \cdot 1,71 + 0,33(-1,98) - 0,127 = 0,00107$$

(x^*, y^*) se comporta como una solución en el sentido que "casi" verifica las ecuaciones, el vector residuo es muy pequeño.



El ángulo entre las dos rectas es muy pequeño y la representación de ellas en la PC puede resultar en una recta paralela y por consiguiente el punto de corte ser muy lejano.

Podría utilizar mayor precisión al realizar los cálculos pero al realizar los cálculos con una PC la precisión tiene un límite.

Ejemplo: Cálculo derivada: \lim cociente incremental

$$f'(x_0) = \lim_{h \rightarrow 0} \frac{f(x_0+h) - f(x_0)}{h}$$

$$\text{si } h \text{ es pequeño: } \Delta h f(x) = \frac{f(x+h) - f(x)}{h} \approx f'(x)$$

$$f(x) = e^x, x_0 = 1 \quad f'(x_0) = e = 2,7183$$

$$\Delta h = \frac{e^{1+h} - e}{h}$$

h	Δh	error	
1	4,67	-1,95	
$1/10$	2,8588	$-1,4 \cdot 10^{-1}$	Hay un h óptimo
$1/100$	2,7319	$-1,36 \cdot 10^{-2}$	para el cual
:			obtengo la mejor
$1/10^8$	2,7183	$66 \cdot 10^{-9}$	aproximación por
$1/10^9$		$-6,59 \cdot 10^{-7}$	cociente incremental
:			
$1/10^{14}$		$-3,5 \cdot 10^{-2}$	

7/08

Notación Binaria.

Usamos 2 dígitos: 0 y 1

Teorema:

Alguno número real x se puede escribir como

$$x = \sum_{k=0}^{k=N} a_k z^k + \sum_{j=1}^{\infty} b_j \cdot \frac{1}{z^j}$$

$$a_k = 0 \text{ ó } 1 \quad b_j = 0 \text{ ó } 1.$$


$$[x]_2 = a_N a_{N-1} \dots a_1 a_0, b_1 b_2 \dots$$

$$\text{Ejemplo } 3,25 = 2 + 1 + 1 \cdot \frac{1}{4} = 1 \cdot 2^1 + 1 \cdot 2^0 + 1 \cdot 2^{-2}$$

$$(3,25)_{10} = (11,01)_2$$

Como pasar de decimal a binario.

Ej: 18,275



Para hallar los b_j tomo la parte fraccionaria y la multiplico por 2.

$$0,275 \times 2 = 0,55 < 1 \rightarrow b_1 = 0$$

$$0,55 \times 2 = 1,10 \geq 1 \rightarrow b_2 = 1$$

$$0,10 \times 2 = 0,20 < 1 \rightarrow b_3 = 0$$

} parte no periódica

$$\begin{aligned}
 0,2 \times 2 = 0,4 < 1 &\rightarrow b_4 = 0 \\
 0,4 \times 2 = 0,8 < 1 &\rightarrow b_5 = 0 \\
 0,8 \times 2 = 1,6 \geq 1 &\rightarrow b_6 = 1 \\
 0,6 \times 2 = 1,2 \geq 1 &\rightarrow b_7 = 1 \\
 0,2 \times 2 = 0,4 < 1 &\rightarrow b_8 = 0
 \end{aligned}
 \quad \left. \begin{array}{l} \text{parte periódica} \\ \text{periodo} \end{array} \right\}$$

$$\rightarrow 18,275 = 10010,010\overline{0011} \dots$$

Hay números que tienen representación finita en base 10 pero al pasar a binario pasan a tener representación infinita.

Como pasar de binario a decimal

$$\text{ej: } (1010,101)_2 =$$

$$\begin{aligned}
 2^3 + 2^1 + \frac{1}{2^1} + \frac{1}{2^3} &= 8 + 2 + \frac{1}{2} + \frac{1}{8} = 10 + 0,5 + 0,125 \\
 &= 10,625
 \end{aligned}$$

Representación en punto flotante:

IEEE 754 Floating Point Standard (1985)

Dos formatos básicos: Simple precisión (32 bits)
Doble precisión (64 bits)

Un número a se almacena en 3 campos

- un signo s
- un exponente e
- una mantisa m

La representación r de a en el caso normal es:

$$r = (-1)^s \cdot (1m) \cdot 2^e$$

FORMATO	Nº de bits	s	m	e	e_{\min}	e_{\max}
Simple	32	1	23	8	-126	127
Doble	64	1	52	11	-1022	1023

Número más grande que se puede representar (realmax)

$$\text{Simple } \sim 2,0 \cdot 2^{127} \approx 3,4028 \cdot 10^{38}$$

$$\text{Doble } \sim 2,0 \cdot 2^{1023} \approx 1,7977 \cdot 10^{308}$$


¿Cuál es el número normalizado positivo más chico que puedo representar?

$$1,00\dots0 \cdot 2^{e_{\min}} = \text{realmin} \quad \begin{cases} \text{simple } 2^{-126} \approx 1,175 \cdot 10^{-38} \\ \text{doble } 2^{-1022} \approx 2,2251 \cdot 10^{-308} \end{cases}$$

Un exponente $e = e_{\min} - 1$ y $m \neq 0$ significa que el número es denormalizado $x = (-1)^e (0m) \cdot 2^{e_{\min}}$

El número más chico denormalizado que se puede representar es

$$\begin{cases} \text{simple } 2^{-126-23} \approx 1,4 \cdot 10^{-45} \\ \text{doble } 2^{-1022-52} \approx 4,94 \cdot 10^{-324} \end{cases}$$



Un resultado mayor que realmax es OVERFLOW

" " menor que el número denormalizado más pequeño es UNDERFLOW — En Matlab se le asigna el valor 0

Otra forma de almacenar : NAN : Not a number

* ej 0/0, log 0, ...

En la norma se admiten dos formas de aproximación:

Redondeo (rounding) : el num. representable más cercano

Truncamiento (chopping) : el " " " \leq " "

Ejemplo: Base 10, mantisa de 4 dígitos, exp de 2 dígitos

$$x = 1,234 \cdot 10^0 + \beta = 5,678 \cdot 10^{-4} = 1,234 + 0,0005678$$

$$= 1,2345678 \quad \begin{cases} \text{Redondeo : } 1,235 \cdot 10^0 \\ \text{Truncamiento : } 1,234 \cdot 10^0 \end{cases}$$

Matlab utiliza redondeo.

Epsilon de la Máquina (EM)

Def: Es el número en punto flotante, positivo, más pequeño que se puede sumar a 1 y obtener un número en punto flotante > 1

depende de:

- simple precisión o doble precisión
- si la aproximación es por redondeo o por truncamiento

Ejemplo: supongamos una aritmética con 4 dígitos decimales

$$\begin{cases} EM = 0,001 \text{ si se trunca} \\ EM = 0,0005 \text{ si se redondea} \end{cases}$$

Si trunco:

$$1,0 + 0,001 = 1,001$$

$$1,0 + 0,000999 = 1,000999 \rightarrow \text{lo almacena como } 1,0$$

Si redondeo:

$$1,0 + 0,00051 = 1,00051 \rightarrow \text{lo almacena como } 1,001$$

$$1,0 + 0,00049 = 1,00049 \rightarrow \dots \quad " \quad " \quad 1,0$$


En Matlab que usa doble precisión y redondea

$$EM = 2,22 \cdot 10^{-16}$$

Simple precisión con redondeo $2^{-24} + 2^{-47} \approx 60 \cdot 10^{-8}$

En doble precisión:

64 bits $\rightarrow s=1$ bit $m=52$ bits.



SHIFT OUT: Es cuando en una suma $x+y=x$, esto ocurre si $|x|$ es muy grande respecto a $|y|$

$$x + \gamma = x(1 + \gamma/x)$$

Si $(\gamma/x) < \epsilon_m \rightarrow x + \gamma$ se almacena como x .

Error de representación:

Es el error que se comete al almacenar un valor.

Sea x un valor y \bar{x} el valor almacenado


Prop: El error relativo de la representación es $\leq \epsilon_m$.

$$\text{Error relativo: } \frac{\bar{x} - x}{x} = \frac{x(1 + \delta_x) - x}{x} = \delta_x$$

$$|\text{Error relativo}| = |\delta_x| \leq \epsilon_m$$


Se tiene: entre dos potencias consecutivas de 2 tenemos

la misma cantidad de números en pto. flotante.



$$\left| \frac{\bar{x} - x}{x} \right| < \left| \frac{\bar{x} - x}{1} \right| \leq \epsilon_m$$

$$\rightarrow |\delta_x| \leq \epsilon_m$$



Error de la suma:

$x + \gamma$ — Tres errores: 1) representación de x

2) " " " γ

3) puede haber error en la suma

de 2 nm en punto flotante

$$(x ej: 1 + 2^{-100} = 1)$$

supongamos $x \in \mathbb{R}$ positivos

$$x - \bar{x}$$

$$\bar{x} - \bar{y} \quad |\text{Error relativo}| = \left| \frac{(\bar{x} + \bar{y}) - (x + y)}{x + y} \right|$$

$$= \left| \frac{(x - x) + (\bar{y} - y)}{x + y} \right| \leq \frac{|\bar{x} - x|}{x + y} + \frac{|\bar{y} - y|}{x + y}$$

$$\bar{x} = x(1 + \delta_x) \rightarrow = \frac{x|\delta_x|}{x + y} + \frac{y|\delta_y|}{x + y} \leq \frac{x\epsilon_M}{x + y} + \frac{y\epsilon_M}{x + y} = \epsilon_M.$$

$$\bar{y} = y(1 + \delta_y)$$

Canceledación catastrófica:

En una resta podemos tener un error relativo muy grande cuando $x \in \mathbb{R}$ son parecidos.

Ejemplo: Raíces de $x^2 - 56x + 1 = 0$

$$r = 28 \pm \sqrt{783}$$

tomo la raíz con 5 dígitos correctos

$$r_1 = 28 + 27,982 = 55,982 \pm 1/2 \cdot 10^{-3}$$

$$r_2 = 28 - 27,982 = 0,018 \pm 1/2 \cdot 10^{-3}$$

en r_2 se obtienen solo 2 dígitos significativos y el error relativo $< 10^{-2}$

Solución: Usamos relaciones entre coeficientes y raíces

$$r_1 \cdot r_2 = 1 \rightarrow r_2 = \frac{1}{r_1} = \frac{1}{55,982} = 0,017863$$

termo independiente

$$(a + b)^2 = a^2 + 2ab + b^2 \rightarrow 2ab = (a + b)^2 - a^2 - b^2$$

$$\text{NE: } 2ab = (gb + 1)^2 - g^2b^2 - 1^2 = g^2b^2 + 2gb + 1 - g^2b^2 - 1 = 2gb$$

11/08

Error de truncamiento - Cociente incremental

$$\Delta_h f(x) = \frac{f(x+h) - f(x)}{h} = \frac{f(x) + f'(x)h + f''(c)\frac{h^2}{2} - f(x)}{h}$$

↑
Taylor
 $c \in [x, x+h]$

$$= f'(x) + f''(c)\frac{h}{2}$$

$$\text{Error de truncamiento: } \Delta_h f(x) - f'(x) = f''(c)\frac{h}{2}$$

Error total del cociente incremental:

cuando calculamos $\frac{f(x+h) - f(x)}{h}$ los valores $f(x+h)$ y $f(x)$

no van a ser en general exactos ya que vamos a operar con sus representaciones en punto flotante.

$$f(x+h) \rightarrow \overline{f(x+h)}$$

$$f(x) \rightarrow \overline{f(x)}$$

$$\text{Error total} = \frac{\overline{f(x+h)} - \overline{f(x)}}{h} - f'(x)$$

$$= \underbrace{\frac{\overline{f(x+h)} - f(x)}{h}}_{\text{Error de redondeo}} - \underbrace{\frac{\overline{f(x+h)} - f(x)}{h}}_{\text{Error de truncamiento}} + \underbrace{\frac{f(x+h) - \overline{f(x+h)}}{h} - f'(x)}_{\text{Error de redondeo}}$$

Error de redondeo.

$$\frac{\overline{f(x+h)} - f(x+h)}{h} + \frac{f(x) - \overline{f(x)}}{h}$$

Error de truncamiento.


$$|\text{Error de truncamiento}| = |f''(c)| \frac{h}{2}$$

$$|\text{Error de redondeo}| \leq \left| \frac{\overline{f(x+h)} - f(x+h)}{h} \right| + \left| \frac{f(x) - \overline{f(x)}}{h} \right|$$

Si tenemos un valor $\gamma \rightarrow \bar{\gamma} = (1 + d_7)\gamma$ con $|d_7| \leq \epsilon_M$

$$\leq \frac{|f(x+h)|}{h} EM + \frac{|f(x)|}{h} EM \approx 2 \frac{|f(x)|}{h} EM \quad \text{si } h \text{ es chico} \rightarrow f(x+h) \approx f(x)$$

$$\Rightarrow |\text{Error total}| \leq \underbrace{\frac{2|f(x)|}{h}}_{\substack{\text{crece cuando} \\ h \text{ disminuye}}} + \underbrace{|f''(c)| \frac{h^2}{2}}_{\substack{\text{crece cuando} \\ h \text{ aumenta}}} = C_1 + C_2$$



$$\frac{d \bar{C}(h)}{d(h)} = 0 = -\frac{2|f(x)|}{h^2} EM + \frac{|f''(x)|}{2}$$

$$h_{\text{optimo}} = 2 \sqrt{\frac{|f(x)|}{|f''(x)|}} EM$$

Si $f(x) \sim f''$ tienen orden de magnitud parecida

→ regla empírica $h_{\text{optimo}} \approx 2EM$: en matlab 10^{-8}

Para mejorar lo anterior → 1) Usar otra fórmula para aproximar $f'(x)$
2) Extrapolación de Richardson

1) Usar en vez de $\Delta h f(x)$ la diferencia centrada

$$= \frac{df(x)}{2h}$$

$$df(x) = \frac{f(x+h) - f(x-h)}{2h}$$

Error de truncamiento de $df(x)$

$$\frac{f(x+h) - f(x-h)}{2h} = \left(f(x) + f'(x)h + f''(x) \frac{h^2}{2} + f'''(x) \frac{h^3}{3!} + \dots \right) -$$

$$\left(f(x) - f'(x)h + f''(x) \frac{h^2}{2} - f'''(x) \frac{h^3}{3!} + \dots \right)$$

$$\rightarrow df(x) = f'(x) + f'''(x) \frac{h^2}{3!} + \dots$$

$$\rightarrow \Delta h f(x) = f'(x) + f'''(c) \frac{h^2}{3!} \quad c \in [x-h, x+h]$$

$\Delta h f(x)$ tiene un error de truncamiento $= f'''(c) \frac{h^2}{3!}$

Para este caso llegamos a:

$$|\text{Error total}| \leq \frac{|f(x)| \varepsilon_M}{h} + \frac{|f'''(c)| h^2}{3!} = g(h)$$

$$h^{\text{optimo}} : \frac{dg(h)}{dh} = -\frac{|f(x)| \varepsilon_M}{h^2} + \frac{|f'''(c)| h}{3} = 0.$$

$$h^{\text{optimo}} = \sqrt[3]{\frac{3|f(x)| \varepsilon_M}{|f'''(c)|}} \quad h^{\text{optimo}} \approx \sqrt[3]{\varepsilon_M}$$

$$\text{ejemplo: } f(x) = e^x \quad x=1 \quad f'(1) = e$$

$$\Delta h f(1) : \begin{aligned} h^{\text{opt}} &\approx 10^{-6} & \text{error} &= 1,36 \cdot 10^{-6} \\ h^{\text{opt}} &\approx 10^{-5} & \text{error} &= 8,58 \cdot 10^{-10} \end{aligned}$$

2) Extrapolación de Richardson

$$\Delta h f(x) = f'(x) + \frac{h^2}{6} f'''(x) + \frac{h^4}{120} f^{(5)}(x) + \dots$$

$$\Delta h_{1/10} f(x) = f'(x) + \frac{1}{100} \frac{h^2}{6} f'''(x) + \frac{1}{10000} \frac{h^4}{120} f^{(5)}(x) + \dots$$

Si combinamos las dos anteriores:

$$\frac{100 \Delta h_{1/10} - \Delta h}{99} = f'(x) - \frac{h^4}{100 \cdot 120} f^{(5)}(x) + \dots$$

→ la expresión $\frac{100 \Delta h_{1/10} - \Delta h}{99}$ es una mejor aproximación de $f'(x)$ que $\Delta h_{1/10}$.

En la práctica se escribe como:

$$\Delta h_{1/10} + \frac{\Delta h_{1/10} - \Delta h}{99} \quad \text{es menos susceptible a errores de redondeo}$$

Obs: no necesito saber el coef de h^4 , solo saber que el de h^3 es 0.

Ejemplo: $f(x) = e^x \quad x=1 \quad f'(1) = e$

h	δh	Error δh	Valor extrapolado	Error valor extrapolado
10^0	3,19...	$4,7 \cdot 10^{-1}$		
10^{-1}	2,7...	$4,5 \cdot 10^{-3}$	2,718...	$-2,3 \cdot 10^{-4}$
10^{-2}		$4,5 \cdot 10^{-5}$		$-2,2 \cdot 10^{-8}$

$\frac{\delta_{1/10} + \delta_{1/10} - \delta_1}{99}$

La mejor estimación extrapolada tiene error $9 \cdot 10^{-12}$
sin extrapolar tenemos el mejor error $\approx 10^{-9}$

Extrapolación de Richardson repetida:

Si llamamos R_h a los valores extrapolados obtenidos

$$R_h = f'(x) + c_1 h^4 + c_2 h^6 + \dots$$

$$R_{h/10} = f'(x) + \frac{c_1 h^4}{10000} + \frac{c_2 h^6}{1000000} + \dots$$

$$\frac{10000 R_{h/10} - R_h}{9999} = f'(x) + kh^6 + \dots = R^{(2)}_h$$

h	δh	Error δh	Error R_h	Error $R_h^{(2)}$
10^0	3,19...	$4,7 \cdot 10^{-1}$	x	x
10^{-1}	2,7...	$4,5 \cdot 10^{-3}$	$-2,3 \cdot 10^{-4}$	x
10^{-2}		$4,5 \cdot 10^{-5}$	$-2,26 \cdot 10^{-8}$	$5,4 \cdot 10^{-10}$

\downarrow

el mejor es 10^{-13}

19/08

$$f: \mathbb{R}^n \rightarrow \mathbb{R}$$

Teorema: $x = (x_1, x_2, \dots, x_n)$ $f(x) = f(x_1, x_2, \dots, x_n)$

$$\Delta f = f(x + \Delta x) - f(x) = f(x_1 + \Delta x_1, x_2 + \Delta x_2, \dots, x_n + \Delta x_n) - f(x_1, x_2, \dots, x_n)$$

$$\Rightarrow \Delta f = \sum_{i=1}^n \frac{\partial f}{\partial x_i} (x + \sigma \Delta x) \Delta x_i \text{ con } \sigma \in [0, 1]$$

dem: Por Taylor $f(x + \Delta x) = f(x) + df|_x \Delta x + (\Delta x)^t \frac{d^2 f}{2!}|_x (\Delta x) + \dots$

$$\text{o bien } f(x + \Delta x) = f(x) + df|_{x+\sigma \Delta x} \Delta x$$


$$df = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_n} \right), \quad \Delta x = \begin{pmatrix} \Delta x_1 \\ \Delta x_2 \\ \vdots \\ \Delta x_n \end{pmatrix} \quad \left(\begin{matrix} \Delta x_1 \\ \Delta x_2 \\ \vdots \\ \Delta x_n \end{matrix} \right)$$

$$\rightarrow f(x + \Delta x) = f(x) + \left(\frac{\partial f}{\partial x_1} (x + \sigma \Delta x), \dots, \frac{\partial f}{\partial x_n} (x + \sigma \Delta x) \right)$$

$$\rightarrow f(x + \Delta x) = f(x) + \sum_{i=1}^{i=n} \frac{\partial f}{\partial x_i} (x + \sigma \Delta x) \cdot \Delta x_i$$

$$\text{además: } |f(x + \Delta x) - f(x)| \leq \sum_{i=1}^n \left| \frac{\partial f}{\partial x_i} (x + \sigma \Delta x) \right| |\Delta x_i|$$

Ejemplo: resistencia en paralelo:



resistencia equivalente

$$\frac{1}{R} = \frac{1}{x} + \frac{1}{y} \quad R = \frac{xy}{x+y}$$

$$\frac{\partial R}{\partial x} = \frac{y^2}{(x+y)^2}$$

$$\frac{\partial R}{\partial y} = \frac{x^2}{(x+y)^2}$$

$$\text{Si } x = 1,523 \pm 0,5 \cdot 10^{-3}$$

$$7 = 2,214 \pm 0,5 \cdot 10^{-3}$$

$$|\Delta R| \leq \frac{2,214^2}{(1,523 + 2,214)^2} \quad (1/2 \cdot 10^{-3}) + \frac{1,523^2}{(1,523 + 2,214)^2} \cdot 10^{-3} = 6,6 \cdot 10^{-4}$$

$$\rightarrow R = 0,9023 \pm 6,6 \cdot 10^{-4}$$

SISTEMAS DE ECUACIONES

$Ax = b$ A matriz $n \times n$ no singular (invertible)

$b \in \mathbb{R}^n$ ($0 \in \mathbb{C}^n$) dato.

$x \in \mathbb{R}^n$ ($0 \in \mathbb{C}^n$) incógnita

x, b vectores columna (matrices $n \times 1$)

Descomposición LU de A. (L: lower, U: upper)

la idea es escribir $A = L \cdot U$ donde L es de la forma

$$L = \begin{bmatrix} 1 & & & \\ L_{21} & 1 & & 0 \\ \vdots & & 1 & \\ & & & 1 \\ L_{n1} & \dots & L_{n,n-1} & 1 \end{bmatrix} \text{ es triangular inferior con } 1 \text{ en la diagonal}$$

$$U = \begin{bmatrix} U_{11} & \dots & U_{1n} \\ U_{22} & \ddots & \vdots \\ \ddots & \ddots & \vdots \\ 0 & & U_{nn} \end{bmatrix} \text{ es triangular superior}$$

¿para qué sirve?

$$Ax = b$$

$$LUx = b \quad \text{Si } Ux = y \text{ entonces } Ly = b$$

este sistema es triangular \rightarrow está escalizado \rightarrow se resuelve fácilmente
pues sus sistemas son triangulares

$Lx = y$ back substitution
 $Ly = b$ forward substitution

$$Ly = b \quad L = \begin{bmatrix} 1 & & & \\ L_{21} & 1 & & \\ \vdots & & 1 & \\ L_{n1} & L_{n2} & \ddots & 1 \end{bmatrix}$$

$$\begin{aligned} y_1 &= b_1 \\ y_2 &= b_2 - L_{21} y_1 \\ y_3 &= b_3 - L_{31} y_1 - L_{32} y_2 \\ &\vdots \\ y_k &= b_k - \sum_{j=1}^{j=k-1} L_{kj} y_j \end{aligned}$$

$$y_n = b_n - \sum_{j=1}^{n-1} L_{nj} y_j$$

$$Ux = y \quad x_n = \frac{y_n}{u_{nn}}$$

$$x_{n-1} = \frac{y_{n-1} - u_{n-1,n} x_n}{u_{n-1,n-1}}$$

$$x_{n-k} = y_{n-k} = \frac{y_{n-k} - \sum_{j=1}^k u_{n-k,n-k+j} x_j}{u_{n-k,n-k}}$$

x_1

flop: floating point operations

flop: 1 operación de punto flotante

En MATLAB: flops manda la cantidad de operaciones en punto flotante.

Wantó me westa resolver el sistema (en flops) para cada ecuación $2x_{k-1}$

en total $2(1+2+3+\dots+n-1) = (n-1)n$ n orden (n^2)
 1º sistema.

El 2º sistema hay que adjuntarle n divisiones:
westa $n^2 - n + 1$ sigue siendo de orden n^2

¿Cómo hallar la descomposición LU?

Se basa en el algoritmo de escalerización (eliminación gaussiana)

$$\text{Ejemplo: } A = \begin{pmatrix} 1 & 1 & 3 & 1 \\ 2 & 3 & 2 & 1 \\ 3 & 2 & 3 & 0 \\ 2 & 1 & 0 & 1 \end{pmatrix} \sim \begin{pmatrix} 1 & 1 & 3 & 1 \\ 0 & 1 & -4 & -1 \\ 0 & -1 & -6 & -3 \\ 0 & -1 & -6 & -1 \end{pmatrix} \begin{array}{l} F_2 - 2F_1 \rightarrow L_{21}=2 \\ F_3 - 3F_1 \rightarrow L_{31}=3 \\ F_4 - 2F_1 \rightarrow L_{41}=2 \end{array}$$

$$\sim \begin{pmatrix} 1 & 1 & 3 & 1 \\ 0 & 1 & -4 & -1 \\ 0 & 0 & -10 & -4 \\ 0 & 0 & -10 & -2 \end{pmatrix} \begin{array}{l} F_3 + F_2 \rightarrow L_{32}=-1 \\ F_4 + F_2 \rightarrow L_{42}=-1 \end{array}$$

$$\sim \begin{pmatrix} 1 & 1 & 3 & 1 \\ 0 & 1 & -4 & -1 \\ 0 & 0 & -10 & -4 \\ 0 & 0 & 0 & 2 \end{pmatrix} = U \quad \rightarrow \quad L = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 2 & 1 & 0 & 0 \\ 3 & -1 & 1 & 0 \\ 2 & -1 & 1 & 1 \end{pmatrix} \quad \begin{array}{l} F_4 - F_3 \rightarrow L_{43}=1 \end{array}$$

$$\text{Ejemplo } A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

$$\begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 0 \\ L & 1 \end{bmatrix}}_{\text{ }} \begin{bmatrix} u & u^n \\ 0 & u^1 \end{bmatrix}$$

$$\begin{bmatrix} u & u^n \\ L-u & Lu^n+u^1 \end{bmatrix} \rightarrow \begin{cases} 0=u \\ 1=u^n \\ Lu=1 \\ Lu^n+u^1=0 \end{cases} \quad \begin{array}{l} \text{Incompatible} \\ \text{Incompatible} \end{array}$$

la matriz A no tiene descomposición LU

Si intercambio filas me queda la matriz identidad $\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$

$= \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ la wal tiene descomposición LU

En gen: Si A es invertible $n \times n$ entonces hay una permutación de filas de A tal que la matriz resultado tiene descomposición LU.

Si en la escaleraización hay que necesariamente en algún momento intercambiar filas \rightarrow A no tiene descomposición LU.

Estas matrices son aquellas tales que sus n determinantes diagonales son $\neq 0$.

$$\xrightarrow{\text{am } \neq 0} \left(\begin{array}{ccc|c} 1 & & & a_{11} \\ -1 & 1 & & a_{12} \\ 0 & 0 & 1 & a_{22} \\ 0 & 0 & -1 & a_{31} \end{array} \right) \rightarrow \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} \neq 0$$

$$\downarrow \quad \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} \neq 0$$

21/08

FINOTEÓ

Ejemplo:

$$\begin{pmatrix} 10 & -7 & 0 \\ -3 & 2,099 & 6 \\ 5 & -1 & 5 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix} = \begin{pmatrix} 7 \\ 3,901 \\ 6 \end{pmatrix}$$

Solución exacta
 $(0, -1, 1)$

Escalerizamos y operamos con 5 dígitos significativos.

$$\begin{pmatrix} 10 & -7 & 0 & | & 7 \\ 0 & -0,001 & 6 & | & 6,001 \\ 0 & 2,5 & 5 & | & 2,5 \end{pmatrix}$$

si seguimos adelante

$$\underbrace{(5 + (25 \cdot 10^3) \cdot 6)}_{1,5 \cdot 10^4} \cdot x_3 = (25 + (2,5 \cdot 10^3) \cdot 6,001)$$

$1,50025 \cdot 10^4$ se redondea
a $1,5002 \cdot 10^4$

$$1,5005 \cdot 10^4$$

$se\ redondea\ a\ 1,5004 \cdot 10^4$

$$\rightarrow x_3 = \frac{1,5004}{1,5005} = 0,99993$$

para x_3 es una buena aproximación, desafortunadamente x_2 debe despejarse de $-0,001x_2 + 6 \cdot 0,99993 = 6,001$

$$\rightarrow x_2 = \frac{1,4 \cdot 10^{-3}}{-1,0 \cdot 10^{-3}} = -1,4$$

y en la primera ecuación $x_1 = -0,28$.

La solución obtenida es muy distinta de la solución exacta
Si en el segundo paso intercambiamos la 2^a fila con la 3^a

$$\left(\begin{array}{ccc|c} 10 & -7 & 0 & 7 \\ 0 & 2,5 & 5 & 25 \\ 0 & -0,001 & 6 & 6,001 \end{array} \right) \rightarrow \text{el siguiente paso quedaria}$$

$$(6 + \underbrace{\frac{0,001}{2,5} \cdot 5}_{multiplicador}) x_3 = 6,001 + \underbrace{\frac{0,001}{2,5} \cdot 2,5}_{6,002}$$

$x_3 = 1$

de la segunda ecuación:

$$2,5x_2 + 5 \cdot 1 = 2,5$$

$$\rightarrow x_2 = -1$$

de la primera ecuación:

$$10x_1 - 7 \cdot 1 + 0 = 7 \rightarrow x_1 = 0$$

Intercambio filas adecuadamente de modo de utilizar multiplicadores pequeños.

Estrategias de pivoteo mas usadas:

1) Pivoteo Parcial ($\Theta(n^2)$)

Si estamos en la posición a_{lk} en la escalierización buscamos el elemento de mayor valor absoluto en $\{a_{lk}, a_{l+1k}, \dots, a_{nk}\}$

Seac r la fila tal que $|a_{rk}|$ es ese valor \rightarrow a continuación intercambiamos la fila k con la fila r. Tenemos que comparar $n+1-k$ numeros. Con esto los multiplicadores del siguiente paso son ≤ 1 .

2) Pivoteo Total ($\Theta(n^3)$)

Identificamos el mayor en valor absoluto. Sea a_{rs}

Intercambiamos fila k con fila r, columna k con columnas.

En cada etapa hay que hacer $(n+1-k)^2$ comparaciones.

3) Rook Pivoting

Intermedio entre Parcial y total.

Identifico el mas grande de la columna.

Si es el mas grande de la fila \rightarrow fin

si no es así \rightarrow me muevo a esa mala posición

y repito. Continua encontrar uno que es el mas grande de la fila y de la columna.

Intercambio fila y columna del encontrado.

$P =$ matriz de permutación = matriz que es el resultado de permutar filas en la matriz identidad

Entrada: A_{nxn} invertible.

Salida: P matriz de permutación

L triangular inferior con 1 en la diagonal

U " Superior

tales que $\underbrace{PA}_{\uparrow \text{permutación de filas de } A} = LU$

- 1) Hacer P la matriz identidad $n \times n$, idem L
- 2) Para i variando entre 1 y n hacer:
- 3) Pivoteo parcial: Buscar el primer j tal que $|a_{ij}|$ sea máximo de $\{|a_{11}|, |a_{12}|, \dots, |a_{1n}|\}$
Intercambiar en P la fila i con la fila j
" " " L " " i " " " j pero dejamos los 1 de la diagonal sin cambiar.

$$\begin{bmatrix} 1 & & \\ L21 & 1 & \\ L31 & L32 & 1 \\ L41 & L42 & 0 & 1 \end{bmatrix} \xrightarrow[\text{F3 con F4}]{\text{Intercambiar}} \begin{bmatrix} 1 & & \\ L21 & 1 & \\ L41 & L42 & 1 \\ L31 & L32 & 0 & 1 \end{bmatrix}$$

- 4) Para $j > i$ hasta $j = n$ hacer: $l_{ji} = \frac{a_{ji}}{a_{ii}}$

cambiar la fila F_j de A por $F_j - l_{ji} F_i$

- 5) Incrementar i en 1 y volver a 2)

Al finalizar tenemos como último valor de A a U .

Aplicación:

$$Ax = b$$

Hallo las matrices P, L, U

$$\rightarrow APx = Pb$$

$$\rightarrow LUx = Pb = b'$$

$$\rightarrow LUx = b' \rightarrow \begin{cases} 1) Lx = b' \\ 2) Ux = y \end{cases}$$

Costo operacional de hallar la U .

en el primer momento:

$$a_{11} \ a_{12} \ \dots \ a_{1n}$$

$i=1$ cálculo de los multiplicadores

$$a_{21} \ a_{22} \ \dots \ a_{2n}$$

$$l_{21} = \frac{a_{21}}{a_{11}}, \dots, l_{nn} = \frac{a_{nn}}{a_{11}}$$

$$\vdots \qquad \vdots$$

$$a_{nn}$$

$$a_{11} \ a_{12} \ \dots \ a_{1n}$$

$n-1$ divisiones

$$(n-1) \text{ veces} \quad \left\{ \begin{array}{l} F_2 - l_{21}F_1 \\ F_3 - l_{31}F_1 \\ \vdots \\ F_n - l_{n1}F_1 \end{array} \right.$$

$$\begin{aligned} F_2 - l_{21}F_1 &: (a_{21}, a_{22}, \dots, a_{2n}) - l_{21}(a_{11}, a_{12}, \dots, a_{1n}) \\ &= (0, a_{22} - l_{21}a_{12}, \dots, \underline{a_{2n} - l_{21}a_{1n}}) \end{aligned}$$

2 operaciones

resta $z(n-1)$

$$\begin{aligned} \rightarrow \text{en total} \quad z(n-1)^2 + n &\quad (\text{para } i=1) \\ z(n-2)^2 + n-1 &\quad (\text{para } i=2) \\ \vdots \\ z(1)^2 + 2 &\quad (\text{para } i=n-1) \end{aligned}$$

$$\text{Total} = z(1^2 + 2^2 + \dots + (n-1)^2) + 2 + 3 + \dots + n$$

$$1 + 2^2 + \dots + n^2 = \frac{n(n+1)(2n+1)}{6}$$

$$1 + 2 + \dots + n = \frac{n(n+1)}{2}$$

$$\text{Costo total} : \frac{z n(n+1)(2n+1)}{6} + \frac{n(n+1)}{2}$$

$$= \frac{z}{3} n^3 + \dots \approx \Theta(n^3) \quad (\text{orden } n^3)$$

$$Ax = b$$

$$A \rightarrow L.U \quad \text{westa } \frac{2n^3}{3} + \dots = O(n^3)$$

$$\left. \begin{array}{l} L.Ux = b \\ Ux = y \end{array} \right\} L_U = b \quad \text{westa } n^2 + \dots = O(n^2)$$

$$Ux = y \quad " \quad n^2 + \dots = O(n^2)$$

$$Ax = b \text{ costaría } \frac{2n^3}{3} + \dots + n^2 + \dots + n^2 + \dots = \frac{2n^3}{3} + \dots + 2n^2 + \dots$$

Un solo sistema $Ax = b$, escalizando, costaría $\frac{2n^3}{3} + \dots$

Supongamos un programa en el cual hay que resolver varios sistemas : $Ax = b_k \quad k=1, 2, \dots, N$.

Si cada vez escalarizo, la parte de resolver los sistemas estaría costando : $N\left(\frac{2n^3}{3} + \dots\right)$

Si hago la LU de A en el principio y luego la uso para cada sistema : $\frac{2n^3}{3} + N(2n^2) + \dots$

Si $N > 1$ el 2º valor es más chico.

Cálculo de la inversa de A

$$A^{-1} \text{ verifica : } Ax = \begin{bmatrix} 1 & & & 0 \\ & 1 & & \\ & & 1 & \\ 0 & \dots & & 1 \end{bmatrix} = I_{n,n}$$

\rightarrow (igualdad de la columna k -ésima) $= Ax^{(k)} = e^k = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \leftarrow \text{pos } k$

$$\text{esto costaría, con el esquema anterior} \\ \frac{2n^3}{3} + \dots + n(2n^2 + \dots) = \frac{8n^3}{3} + \dots = O(n^3)$$

Si quiero hacer $A \cdot B$ con A y B matrices $n \times n$.

Tengo que calcular las n^2 posiciones:

$$(A \cdot B)_{i,j} = \sum_{k=1}^{n^2} a_{ik} b_{kj} = (a_{11}b_{1j} + a_{12}b_{2j} + \dots + a_{1n}b_{nj})$$

westa n productos y $n-1$ sumas.

$$A \cdot B \text{ westa } n^2(n-1) \text{ flops} = 2n^3 + \dots = \mathcal{O}(n^3)$$

Def: Sea A , $n \times n$, real, simétrica

A es definida positiva si $x^T A x > 0 \quad \forall x \neq \vec{0}$

Teorema: los valores propios de A son positivos.

dem: Por el teorema espectral los valores propios son reales

Sea λ un valor propio y $\vec{v} \neq \vec{0}$ un vector propio asociado

$$\rightarrow \vec{v}^T A \vec{v} = \vec{v}^T (\lambda \vec{v}) = \lambda \vec{v}^T \vec{v} = \lambda \|\vec{v}\|^2 > 0 \Rightarrow \lambda > 0.$$

Además los determinantes diagonales de A son positivos

(vale el reciproco: si los det. diag. son positivos $\Rightarrow A$ definida positiva)

ejemplo:

$$\begin{bmatrix} 2 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 3 \end{bmatrix} \quad 2 > 0.$$

$$\begin{vmatrix} 2 & 1 \\ 1 & 1 \end{vmatrix} = 2 - 1 = 1 > 0.$$

$$\begin{vmatrix} 2 & 1 & 0 \\ 1 & 1 & 1 \\ 0 & 1 & 3 \end{vmatrix} = 6 - 2 - 3 = 1 > 0.$$

A es definida positiva.

Factorización de Choleski $A = L \cdot L^T$

A real simétrica definida positiva.

L es triangular inferior $L = \begin{bmatrix} l_{11} & & & 0 \\ l_{21} & l_{22} & & \\ \vdots & & & \\ l_{n1} & \dots & l_{nn} \end{bmatrix}$

$$A = L \cdot L^t$$

$$a_{ik} = \sum_{j=1}^{j=k} l_{ij} \cdot l_{kj} \quad i \geq k$$

$$\rightarrow a_{ik} = \sum_{j=1}^{j=k} l_{ij} \cdot l_{kj} + l_{ik} l_{kk} \Rightarrow l_{ik} = a_{ik} - \sum_{j=1}^{j=k-1} l_{ij} l_{kj} \quad i > k$$

además $a_{kk} = \sum_{j=1}^{j=k} l_{kj}^2 = \sum_{j=1}^{j=k-1} l_{kj}^2 + l_{kk}^2 \rightarrow l_{kk} = \sqrt{a_{kk} - \sum_{j=1}^{j=k-1} l_{kj}^2}$

$$k = 1, \dots, n$$

$$l_{11} - l_{21} - \dots - l_{n1}$$

$$l_{22} - l_{32} - \dots - l_{n2}$$

:

$$l_{n-2,n-1}, l_{n,n-1}$$

$$l_{nn}$$

ejemplo:

$$A = \begin{bmatrix} 4 & -2 & -4 \\ -2 & 2 & 4 \\ -4 & 4 & 17 \end{bmatrix}$$

(sub radical es > 0 xq'

A es def. positiva)

$$\lambda_1^z = a_{11} = 4 \rightarrow \lambda_1 = 2$$

$$\lambda_{21} = \frac{a_{21}}{\lambda_{11}} = \frac{-2}{2} = -1$$

$$\lambda_{31} = \frac{a_{31}}{\lambda_{11}} = \frac{-4}{2} = -2$$

$$l_{22} = \sqrt{2 - \lambda_{21}^2} = \sqrt{2 - (-1)^2}$$

$$l_{32} = a_{32} - \sum_{k=1}^{k=2} l_{3k} l_{2k} = \frac{a_{32} - l_{31} l_{21}}{l_{22}} = \frac{(4) - (-2)(-1)}{1} = 2$$

$$l_{33} = \sqrt{a_{33} - l_{31}^2 - l_{32}^2} = \sqrt{17 - 4 - 4} = 3.$$

$$\rightarrow L = \begin{bmatrix} 2 & 0 & 0 \\ -1 & 1 & 0 \\ -2 & 2 & 3 \end{bmatrix}$$

$$L \cdot L^t = A$$

Ventajas: 1) mitad de operaciones que la L.U.

2) es estable sin necesidad de pivoteo porque


$$a_{kk} = \sum_{j=1}^k b_{kj}^2 \rightarrow b_{kj} \leq \sqrt{a_{kk}} \quad \forall j = 1, 2, \dots, k.$$

Ejemplo:

$$\gamma'' + f(x)\gamma = g(x) \quad \gamma(0) = a$$

$$\gamma(1) = b$$

f, g conocidas., γ función a determinar.



$$x_i = \frac{i}{n} \quad i = 0, 1, 2, \dots, n.$$

$$\gamma''(x_i) \approx \frac{\gamma(x_{i-1}) - 2\gamma(x_i) + \gamma(x_{i+1})}{h^2} = \frac{\gamma(x_i-h) - 2\gamma(x_i) + \gamma(x_i+h)}{h^2}$$

$$= \gamma(x_i) - \gamma'(x_i)h + \gamma''(x_i)\frac{h^2}{2} - \cancel{\gamma'''(x_i)\frac{h^3}{6} + \gamma^{(4)}(x_i)\frac{h^4}{24} + \dots} - 2\gamma(x_i) + \dots / h^2$$

$$\Delta^2 \gamma = \gamma''(x_i) + \gamma^{(4)}(x_i)\frac{h^2}{12} + \dots$$

$$\Delta^2 \gamma = \gamma''(x_i) + \gamma^{(4)}(c_i)\frac{h^2}{12}$$

$$\gamma''(x_i) / \frac{\gamma(x_{i-1}) - 2\gamma(x_i) + \gamma(x_{i+1})}{h^2} = \Delta^2 \gamma.$$

Ecación k-ésima:

$$\gamma''(x_k) + f(x_k)\gamma(x_k) = g(x_k)$$

$$\frac{\gamma(x_{k-1}) - 2\gamma(x_k) + \gamma(x_{k+1})}{h^2} - f(x_k)\gamma(x_k) = g(x_k)$$

$$\gamma_k = \gamma(x_k)$$

Sistema queda:

$$\begin{bmatrix} & & & 1/h^2 \\ & \ddots & & \\ & & 0 & \\ & & -1/h^2 & \\ & & & \ddots & \\ & & & & 1/h^2 \end{bmatrix} \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_{n-1} \end{pmatrix} = \begin{pmatrix} g(x_1) \\ g(x_2) \\ \vdots \\ g(x_{n-1}) \end{pmatrix}$$

sistema tridiagonal

28/08

MATLAB: RETROBARRA (\)

Sistema: $Ax = b$

Solución MATLAB: $x = A \setminus b$

Si b es una matriz: $n \times k$ $A \setminus b$ es una matriz $\times n \times k$
tal que $Ax = b$.

$A \setminus b$ matemáticamente es equivalente a $A^{-1}b$ (\leftarrow Matlab $= \text{inv}(A) * b$)

NORMA:

Norma de un vector:

$$\| \cdot \|: \mathbb{R}^k \rightarrow \mathbb{R}^+ \cup \{0\} \quad (o \quad C^k \rightarrow \mathbb{R}^+ \cup \{0\})$$

$$1) \|u\| \geq 0, \quad \|u\| = 0 \iff u = \vec{0}$$

$$2) \|xu\| = |x| \|u\|$$

$$3) \|u+v\| \leq \|u\| + \|v\| \quad (\text{desigualdad triangular})$$

Norma p: $p \geq 1$, p real

$$\|x\|_p = \|(x_1, x_2, \dots, x_k)\|_p = \left(|x_1|^p + |x_2|^p + \dots + |x_k|^p \right)^{1/p}$$

En particular: $p=2$: norma euclídea

$$\|x\|_2 = \sqrt{|x_1|^2 + |x_2|^2 + \dots + |x_k|^2}$$

$p=1$: norma 1.

$$\|x\|_1 = |x_1| + |x_2| + \dots + |x_k|$$

norma infinito: $\|x\|_\infty = \max \{ |x_i| \} \quad (= \lim_{p \rightarrow +\infty} \|x\|_p)$

Ejemplo:

$$\begin{array}{c} \uparrow \\ \begin{pmatrix} 1 & 2 \end{pmatrix} \\ \downarrow \end{array}$$

$$\|(1, 2)\|_1 = 3$$

$$\|(1, 2)\|_2 = \sqrt{5}$$

$$\|(1, 2)\|_\infty = 2$$

Norma de una Matriz:

$\mathbb{R}^{m \times n}$ = matriz real $m \times n$ ($\mathbb{C}^{m \times n}$ idem complejos)

$\| \cdot \| : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^+ \cup \{0\}$ tal que:

- 1) $\|A\| > 0$; $\|A\| = 0 \iff A = 0$
- 2) $\|\lambda A\| = |\lambda| \|A\|$
- 3) $\|A+B\| \leq \|A\| + \|B\|$.

Otros:

$$\begin{aligned} &\rightarrow \|A \cdot B\| \leq \|A\| \cdot \|B\| \text{ (submultiplicativa)} \\ &\rightarrow \|I\| = 1 \\ &\rightarrow \|A^T\| = \|A\| \end{aligned}$$

Norma de matriz inducida por una norma de vector:

Consideremos matrices cuadradas $\in \mathbb{R}^{k \times k}$ ($\text{o } \mathbb{C}^{k \times k}$)

En \mathbb{R}^k tenemos una cierta norma: $\| \cdot \| : \mathbb{R}^k \rightarrow \mathbb{R}^+ \cup \{0\}$

Def: Si A es una matriz $k \times k$

$$\text{Sea } \|A\| = \max_{x \neq \vec{0}} \left\{ \frac{\|Ax\|}{\|x\|} \right\} = \max_{\|x\|=1} \{ \|Ax\| \}$$

$$\text{si } \|x\| \neq 1 : \frac{\|Ax\|}{\|x\|} = \|A \left(\frac{\|x\| \cdot \frac{x}{\|x\|}}{\|x\|} \right)\| = \frac{\|x\|}{\|x\|} \frac{\|A \frac{x}{\|x\|}\|}{\left\| \frac{x}{\|x\|} \right\|} \xrightarrow{\|x\|=1} 1$$

$$= \|A \cdot \frac{x}{\|x\|}\|$$

Teorema: La anterior es una norma de matriz.

Propiedad: $\|Ax\| \leq \|A\| \|x\|$

Dem: Si $x \neq \vec{0} \rightarrow \frac{\|Ax\|}{\|x\|} \leq \|A\| \rightarrow \|Ax\| \leq \|A\| \cdot \|x\|$

Si $x = \vec{0}$ tengo igualdad: $\|\vec{0}\| = \|A\| \cdot \|\vec{0}\|$

$$\text{Ejemplo: } A = \begin{bmatrix} 2 & 1 \\ 3 & 4 \end{bmatrix}$$

Calcular $\|A\|_\infty$. (=norma de matriz inducida cuando tomo en \mathbb{R}^2 la norma infinito:

$$\|(x, y)\|_\infty = \max \{|x|, |y|\}$$

Veamos que $\|A\|_\infty = 7$

Sean $\begin{pmatrix} x \\ y \end{pmatrix} / \| \begin{pmatrix} x \\ y \end{pmatrix} \|_{\infty} = 1$ (\circ sea $\max \{|x|, |y|\} = 1$)

$$Ax = \begin{bmatrix} 2 & 1 \\ 3 & 4 \end{bmatrix} \begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 2x + y \\ 3x + 4y \end{pmatrix}$$

$$\rightarrow \|Ax\|_{\infty} = \max \{ |2x + y|, |3x + 4y| \} \leq 7$$

$\max \{|x|, |y|\} = 1$

$$|2x + y| \leq 2|x| + |y| \leq 2 + 1 = 3$$

$$|3x + 4y| \leq 3|x| + 4|y| \leq 3 + 4 = 7$$

$$\max \{ \|Ax\|_1, \|Ax\|_{\infty} \} = \|A\| \rightarrow \text{si } x=1, y=1 \text{ queda } \|A\|_1 = 7$$

$\|x\|=1$

$$\Rightarrow \|A\|_{\infty} = 7$$

Prop: Si A es $n \times n$

$$\|A\|_{\infty} = \max_{1 \leq i \leq n} \left\{ \sum_{j=1}^n |a_{ij}| \right\}$$

ejemplo: $A = \begin{pmatrix} -1 & 2 & 3 \\ -2 & 4 & 1 \\ 2 & -3 & -3 \end{pmatrix}$

$$\|A\|_{\infty} = \max \{ 6, 7, 8 \} = 8$$

$$\|A\|_1 = \max_{1 \leq i \leq n} \left\{ \sum_{j=1}^n |a_{ij}| \right\}$$

para el ejemplo anterior $\|A\|_1 = \max \{ 5, 9, 7 \} = 9$

$$(\|A\|_2)^2 = \max \{ \lambda / \lambda \text{ es valor propio de } A^T A \}$$

es def pos. (por Choleski)

Def: A matriz $n \times n$

Radio espectral de $A = \rho(A) = \max \{ |\lambda| / \lambda \text{ es valor propio de } A \}$

Prop: $\rho(A) \leq \|A\|$ si $\| \cdot \|$ es una norma de matriz que cumple $\|Ax\| \leq \|A\| \|x\|$

Dem: Sea λ un valor propio de A

sea $v \neq 0$ un vector propio asociado: $Av = \lambda v$

$$\Rightarrow \|Av\| = \|\lambda v\|$$

$$\text{tenemos: } \|Av\| \leq \|A\| \|v\| \quad \Rightarrow \|\lambda v\| = |\lambda| \|v\|$$

Prop: La norma inducida es submultiplicativa.

- $\rightarrow |\lambda| \|v\| \leq \|A\| \|v\|$ como $v \neq 0 \rightarrow \|v\| \neq 0$
 $\Rightarrow |\lambda| \leq \|A\|$ vale para todos los valores propios de A .
 $\rightarrow \rho(A) \leq \|A\|$.

MÉTODOS ITERATIVOS.

$$Ax = b$$

La idea es partiendo de un x inicial, $x^{(0)}$, ir generando una sucesión ($\in \mathbb{R}^n$), $x^{(1)}, x^{(2)}, \dots, x^{(k)}, \dots$ que se intenta que converja a la solución del sistema x^* ($Ax^* = b$)

MIG: método iterativo general.

$$Ax = b \quad A = M + N \quad (N = A - M)$$

partir A en 2 matrices.

$$(M+N)x = b$$

$$\Rightarrow Mx = -Nx + b$$

Esto sugiere la iteración siguiente:

$$Mx^{(k+1)} = -Nx^{(k)} + b$$

$$Mx^{(k+1)} = (M - N)x^{(k)} + b$$

$$M \text{ se toma invertible: } \rightarrow x^{(k+1)} = \underbrace{M^{-1}(M-N)x^{(k)}}_B + \underbrace{M^{-1}b}_f$$

$$x^{(k+1)} = Bx^{(k)} + f$$

matriz de
iteración

Método de Jacobi

Se toma $M = D =$ la diagonal de A

$$\begin{array}{l} \text{Ejemplo: } 4x + 7 = 5 \\ \quad x + 47 = 5 \end{array} \quad \begin{array}{l} 4x = 5 - 7 \\ \quad 47 = 5 - x \end{array} \quad \left\{ \begin{array}{l} x^{(k+1)} = \frac{5 - 7^{(k)}}{4} \\ 7^{(k+1)} = \frac{5 - x^{(k)}}{4} \end{array} \right.$$

$$x^{(0)} = \begin{pmatrix} x_0 \\ \vdots \\ x_p \end{pmatrix} = \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix} \rightarrow x^{(1)} = \begin{pmatrix} x_1 \\ \vdots \\ x_1 \end{pmatrix} = \begin{pmatrix} 5/4 \\ \vdots \\ 5/4 \end{pmatrix} \rightarrow x^{(2)} = \begin{pmatrix} x_2 \\ \vdots \\ x_2 \end{pmatrix} = \begin{pmatrix} 15/16 \\ \vdots \\ 15/16 \end{pmatrix}$$

$\rightarrow \dots \rightarrow x^{(k)} \dots$

2/09.

Si $A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \Rightarrow M = \begin{bmatrix} a_{11} & a_{22} & 0 & \cdots \\ 0 & \ddots & \vdots & \vdots \\ & & a_{nn} & \end{bmatrix}$

$$x_1^{(k+1)} = -\frac{a_{12}x_2^{(k)} + a_{13}x_3^{(k)} + \dots + a_{1n}x_n^{(k)} + b_1}{a_{11}} = \left(-\sum_{j=1}^n a_{1j}x_j^{(k)} \right) + b_1$$

$$x_i^{(k+1)} = \left(-\sum_{j \neq i} a_{ij}x_j^{(k)} \right) + b_i$$

$$B_{JACOBI} = \begin{bmatrix} 0 & -\frac{a_{12}}{a_{11}} & -\frac{a_{13}}{a_{11}} & \cdots & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & -\frac{a_{23}}{a_{22}} & \cdots & -\frac{a_{2n}}{a_{22}} \\ & & 0 & \ddots & \vdots \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & \ddots & \ddots & 0 \end{bmatrix}$$

Obs: Propiedad: Si A es invertible \exists una permutación de filas de A tal que no hay ningún elemento nulo en la diagonal.

MÉTODO DE GAUSS - SEIDEL:

En las fórmulas anteriores uso los nuevos valores calculados a medida que los voy generando:

$$x_i^{(k+1)} = \frac{-\sum_{j < i} a_{ij}x_j^{(k+1)} - \sum_{j > i} a_{ij}x_j^{(k)}}{a_{ii}} + b_i$$

$$\text{Ejemplo: } x_1 + 2x_2 = 3$$

$$2x_1 + 2x_2 = 1$$

$$x^{(0)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \rightarrow \begin{cases} \text{Jacobi} & x^{(1)} = \begin{pmatrix} 3 \\ 1 \end{pmatrix} \\ \text{G-S} & x^{(1)} = \begin{pmatrix} 3 \\ -5/2 \end{pmatrix} \end{cases}$$

Para Gauss-Seidel si $A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \ddots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix} \Rightarrow$

$M = \begin{bmatrix} a_{11} & & & 0 \\ a_{21} & a_{22} & & 0 \\ \vdots & \vdots & \ddots & \\ 0 & 0 & \dots & 0 \end{bmatrix}$ tomo la matriz triangular inferior.

$$B_{\text{G-S}} = - \begin{bmatrix} a_{11} & & & 0 \\ a_{21} & a_{22} & & 0 \\ \vdots & \vdots & \ddots & \\ 0 & 0 & \dots & 0 \end{bmatrix}^{-1} * \begin{bmatrix} 0 & a_{12} & \dots & a_{1n} \\ 0 & 0 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & 0 & \dots & 0 \end{bmatrix} \quad x^{(k+1)} = Bx^{(k)} + f$$

Estudio de la Convergencia

$$x^{(k+1)} = Bx^{(k)} + f$$

Supongamos x^* es la solución exacta del sistema: $Ax^* = b$.

$$\text{o bien } x^* = Bx^* + f$$

Error del iterado k -ésimo ($x^{(k)} - x^* = e^{(k)}$)

$$x^{(k+1)} = Bx^{(k)} + f$$

$$- x^* = Bx^* + f$$

$$x^{(k+1)} - x^* = B(x^{(k)} - x^*) \rightarrow \boxed{e^{(k+1)} = Be^{(k)}}$$

$$\begin{aligned} e^{(k+1)} &= Be^{(k)} = (B(Be^{(k-1)})) = B^2e^{(k-1)} = \dots = B^{k+1}e^0 \\ \rightarrow \boxed{e^k &= B^ke^0} \end{aligned}$$

Teorema:

El método iterativo converge a $x^0 \Leftrightarrow \rho(B) < 1$

dem: si $\rho(B) \geq 1 \rightarrow \exists \lambda$, valor propio de B tal que $|\lambda| \geq 1$.

Sea $\vec{v} + \vec{o}$ un vector propio asociado a $\lambda \rightarrow$

$$B\vec{v} = \lambda\vec{v}$$

$$B^2\vec{v} = B(B\vec{v}) = B(\lambda\vec{v}) = \lambda B\vec{v} = \lambda(\lambda\vec{v}) = \lambda^2\vec{v}$$

:

$$B^k\vec{v} = \lambda^k\vec{v} \quad (\text{Como } |\lambda| \geq 1) \quad \vec{v} + \vec{o} \rightarrow B^k\vec{v} + \vec{o}$$

Si $e^0 = \vec{v}$ (o sea $x^0 = \vec{v} + \vec{x}^*$) $\rightarrow e^k + \vec{o} \rightarrow$ el método iterativo no converge

b) Supongamos que $\rho(B) < 1$.

Veamos que $B^k \rightarrow 0$ (la matriz es nula)

Si B es diagonalizable $B = P^{-1}DP$

$$D = \begin{bmatrix} \lambda_1 & & & \\ & \ddots & & \\ & & \lambda_n & \end{bmatrix}$$

$$B^2 = (P^{-1}DP)(P^{-1}DP) = P^{-1}D^2P$$

:

$$B^k = P^{-1}D^kP = P^{-1} \begin{bmatrix} \lambda_1^k & & & \\ & \ddots & & \\ & & \lambda_n^k & \end{bmatrix} P \quad (\text{Como } \rho(B) < 1 \rightarrow |\lambda_i| < 1 \forall i) \\ \lambda_i^k \rightarrow 0 \quad \forall i$$

Caso general: Usamos la forma canónica de Jordan.

$$B = P^{-1}JP$$

$$J = \begin{bmatrix} J_1(\lambda_1) & & & \\ & J_2(\lambda_2) & \dots & 0 \\ & & \ddots & \\ 0 & & & J_s(\lambda_s) \end{bmatrix}$$

diagonal
x bloques.

$$J_i(\lambda_i) = \begin{bmatrix} \lambda_i & & & \\ 1 & \lambda_i & & \\ & \ddots & \ddots & \\ & & 1 & \lambda_i \end{bmatrix}$$

$$B^k = P^{-1} J^k P$$

$$J^k = \begin{bmatrix} J_1(\lambda_1)^k & & & \\ & J_2(\lambda_2)^k & & 0 \\ & & \ddots & \\ 0 & & & J_s(\lambda_s)^k \end{bmatrix}$$

$$J_i(\lambda_i)^k = \begin{bmatrix} \lambda_i^{(k)} & & & \\ & \lambda_i^{(k)} & & 0 \\ & & \ddots & \\ & & & \lambda_i^{(k)} \end{bmatrix} \left\{ \begin{array}{l} \text{primera} \\ \text{diagonal} \\ \text{filar} \end{array} \right.$$

$\hookrightarrow C_1 \lambda_i^{k-1} = k \lambda_i^{k-1} \rightarrow 0$
 $\downarrow k \rightarrow \infty$
 $C_{Mi-s} \lambda_i^{k-m+1} \rightarrow \text{tiende } 0$

Obs: Si $p(B) \geq 1$ el método puede converger ya creciendo $x^{(0)}$.

Def: A es una matriz estrictamente diagonal dominante por filas si $|a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|$

Ejemplo:

$$\begin{bmatrix} -3 & 1 & 1 \\ -5 & 7 & 1 \\ 4 & 3 & 3 \end{bmatrix} \quad \begin{array}{l} 3 > 2 \\ 7 > 6 \\ 8 > 7 \end{array}$$

Teo: Para las matrices anteriores entonces Jacobi y Gauss-Seidel convergen.

dem: (Jacobi)

$$BJ = \begin{bmatrix} 0 & -\frac{a_{12}}{a_{11}} & -\frac{a_{13}}{a_{11}} & \dots & -\frac{a_{1,n-1}}{a_{11}} & -\frac{a_{1n}}{a_{11}} \\ -\frac{a_{21}}{a_{22}} & 0 & -\frac{a_{23}}{a_{22}} & \dots & \frac{a_{2,n-1}}{a_{22}} & -\frac{a_{2n}}{a_{22}} \\ \vdots & & \ddots & & & \\ -\frac{a_{n1}}{a_{nn}} & -\frac{a_{n2}}{a_{nn}} & \dots & -\frac{a_{n,n-1}}{a_{nn}} & 0 & \end{bmatrix}$$

MN (Teo)

$$\|B_J\|_{\infty} = \max \left\{ \frac{|a_{11}| + |a_{13}| + \dots + |a_{1n}|}{|a_{11}|}, \frac{|a_{21}| + |a_{23}| + \dots + |a_{2n}|}{|a_{21}|}, \dots, \frac{|a_{m1}| + |a_{m3}| + \dots + |a_{mn}|}{|a_{m1}|} \right\}$$

Si A es diag dominante \rightarrow todos los términos son < 1
 $\rightarrow \|B_J\|_{\infty} < 1$ como $\varrho(B_J) \leq \|B\|_{\infty} \Rightarrow \varrho(B_J) < 1$
 \Rightarrow El método converge

Propiedad: Si A es simétrica definida positiva \Rightarrow
Gauss-Seidel converge.

El radio espectral determina además la velocidad de la convergencia.

Se puede probar que $\frac{\|e^{(k+1)}\|}{\|e^k\|} \rightarrow \varrho(B)$

Si $\varrho(B) = 1/2$ nos dice que (asintóticamente) el error se divide por 2 (en norma) por cada iteración que damos

Ejemplo:

$$A = \begin{bmatrix} 4 & 3 \\ 3 & 228 \end{bmatrix}$$

$$\varrho_{\text{Jacobi}} = 0,9934.$$

$$Ax = \begin{pmatrix} 7 \\ 5,28 \end{pmatrix} \quad x^* = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\varrho_{\text{GS}} = 0,9868.$$

$$x^{(0)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} \xrightarrow{100 \text{ iteraciones}} \begin{pmatrix} 1,2021 \\ 0,7341 \end{pmatrix}$$

MÉTODO SOR (Sobre Relajación)

$$\Delta x = b$$

Multiplico por w , real: $w\Delta x = wb$.

$$wA = M(w) + N(w)$$

$$wA = \begin{bmatrix} w_{11} & w_{12} & \dots & w_{1n} \\ w_{21} & w_{22} & \dots & w_{2n} \\ \vdots & \vdots & & \vdots \\ w_{m1} & w_{m2} & \dots & w_{mn} \end{bmatrix} = \begin{bmatrix} a_{11} & & & 0 \\ w_{21}a_{22} & \ddots & & 0 \\ \vdots & \ddots & \ddots & \vdots \\ w_{m1}\dots w_{m,n-1}a_{mn} & & & 0 \end{bmatrix} + \begin{bmatrix} (w-1)a_{11} & w_{12} & \dots & w_{1n} \\ (w-1)a_{22} & \ddots & & \vdots \\ \vdots & \ddots & \ddots & \vdots \\ (w-1)a_{mn} & w_{m1} & \dots & (w-1)a_{nn} \end{bmatrix}$$

$$M(w)x^{(k+1)} = -N(w)x^{(k)} + wb$$

$$\text{o bien: } x^{(k+1)} = -\underbrace{M^{-1}(w)N(w)}_{B_{SOR}}x^{(k)} + M^{-1}(w)wb$$

$$\text{Queda: } x_j^{(k+1)} = (1-w)x_j^{(k)} + w \left(-\sum_{r=1}^{j-1} \frac{a_{jr}}{a_{jj}} x_r^{(k+1)} - \sum_{r=j+1}^m \frac{a_{jr}}{a_{jj}} x_r^{(k)} + \frac{b_j}{a_{jj}} \right)$$

Obs: si $w=1$ SOR es igual a Gauss-Seidel

Teorema: Si $w \notin [0, 2]$ el método SOR no converge.

$$\underline{\text{dem: }} |\det(B_{SOR})| = |\det(-M^{-1}(w).N(w))| = \frac{|\det(N(w))|}{|\det(M(w))|}$$

$$= |(w-1)a_{11}(w-1)a_{22}(w-1)a_{33} \dots (w-1)a_{nn}| = |(w-1)^n| = \\ a_{11}a_{22} \dots a_{nn} |(w-1)|^n$$

$\det(B_{SOR}) = \text{producto de sus valores propios} = \lambda_1 \cdot \lambda_2 \dots \lambda_n$

$$\rightarrow |\lambda_1| |\lambda_2| \dots |\lambda_n| = |w-1|^n$$

Si $w \notin [0, 2] \rightarrow |w-1| > 1 \rightarrow |w-1|^n > 1$.

$$\rightarrow |\lambda_1| |\lambda_2| \dots |\lambda_n| > 1 \rightarrow \exists \lambda_i / |\lambda_i| > 1 \rightarrow |\det(B_{SOR})| > 1$$

SOR no converge.

Ejemplo:

$$A = \begin{bmatrix} 3 & 1 & 1 \\ 1 & 2 & 2 \\ 1 & 2 & 2.5 \end{bmatrix}$$

$$R_{Gauss-Seidel} = 0.8$$

MNT.

$$w = 0,5 \rightarrow q = 0,993$$

$$w = 1,5 \rightarrow q = 0,566$$

$$w = 1,4 \rightarrow q = 0,477$$

$$w = 1,3 \rightarrow q = 0,575$$

$$w = 1,45 \rightarrow q = 0,52$$

$$w = 1,35 \rightarrow q = 0,434 \leftarrow$$

Direcciones de parada:

1) Manejando una aproximación al error relativo (en norma)

si $\frac{\|x^{(k)} - x^*\|}{\|x^*\|} < \varepsilon$ terminamos las iteraciones.

Como no conocemos x^*

$$\text{Usamos: } \frac{\|x^{(k+1)} - x^{(k)}\|}{\|x^{(k+1)}\|} < \varepsilon$$

2) Si tengo $\|B\|$ para alguna norma, $\|B\| < 1$ o una constante H / $\|B\| \leq H < 1$

$$x^{(k)} - x^* = -B(x^{(k)} - x^{(k-1)}) + B(x^{(k)} - x^*)$$

cierto porque $\begin{cases} x^* = Bx^* + f \\ x^{(k)} = Bx^{(k-1)} + f \end{cases}$

Tomando normas: $\|x^{(k)} - x^*\| \leq \|B(x^{(k)} - x^{(k-1)})\| + \|B(x^{(k)} - x^*)\|$

$$\rightarrow \|x^{(k)} - x^*\| \leq \|B\| \|x^{(k)} - x^{(k-1)}\| + \|B\| \|x^{(k)} - x^*\|$$

$$\rightarrow \|x^{(k)} - x^*\| \leq \frac{\|B\|}{1 - \|B\|} \|x^{(k)} - x^{(k-1)}\|$$

$$\text{Si } \frac{\|B\|}{1 - \|B\|} \|x^{(k)} - x^{(k-1)}\| < \varepsilon \rightarrow \|x^{(k)} - x^*\| < \varepsilon.$$

Cuando usar métodos iterativos:

1) Matrices esparsas: matrices con muchos ceros.

Una matriz de este tipo, si n es muy grande, no puedo (o es ineficiente) guardarla en memoria. Sin embargo si los elementos de la matriz no todos no son demasiados puedo hallar una solución aproximada usando un método iterativo y no mediante un método directo.

Número de condición de una Matriz.

$$Ax = b \quad x^* \text{ solución exacta}$$

Sea x un candidato a solución (obtenido por algún método)

$$\text{Def: Residuo: } r = b - Ax$$

Si el residuo es pequeño ($\|r\| < \varepsilon$) entonces x puede decir que "casi" resuelve todas las ecuaciones del sistema.

Si x está cercano a x^* ($\|x - x^*\| < \varepsilon$) entonces el residuo es pequeño.

Entonces si r no es pequeño, x no está cerca de x^*

Recíproco: ; si el residuo es pequeño x está cerca de x^* ?

A invertible.

Def: número de condición de $A = \|A\| \|A^{-1}\| = \text{cond}(A)$

obs. depende de la norma que se esté usando.

$$\|A\| = \max_{x \neq \vec{0}} \frac{\|Ax\|}{\|x\|}$$


$$\|A^{-1}\| = \max_{y \neq \vec{0}} \frac{\|A^{-1}y\|}{\|y\|} = \max_{x \neq \vec{0}} \frac{\|x\|}{\|Ax\|} = \max_{x \neq \vec{0}} \frac{1}{\frac{\|Ax\|}{\|x\|}} = \frac{1}{\min_{x \neq \vec{0}} \frac{\|Ax\|}{\|x\|}}$$

Cambio de variable $y = Ax$

$$\Rightarrow \text{cond}(A) = \frac{\max_{x \neq \vec{0}} \frac{\|Ax\|}{\|x\|}}{\min_{x \neq \vec{0}} \frac{\|Ax\|}{\|x\|}} = \frac{\max_{\|x\|=1} \|Ax\|}{\min_{\|x\|=1} \|Ax\|}$$

Si la matriz no es invertible

$$\rightarrow \text{cond}(A) = \infty$$



Cuando el número de condición es razonable \rightarrow se cumple el recíproco: si el residuo es pequeño entonces x está cerca de x^* de lo contrario, el recíproco no se cumple.

9/09/08

Número de Condición

$$\text{Cond}(A) = \|A\| \|A^{-1}\| = \frac{\max_{\|x\|=1} \|Ax\|}{\min_{\|x\|=1} \|Ax\|}$$

- Propiedades:
- 1) $\text{Cond } A \geq 1$
- 2) $\text{Cond } (I^n) = 1$
- 3)

Esto es porque $\|Ax\|_2 = \|x\|_2$ si A es ortogonal

Si $\|x\|_2 = 1 \rightarrow \|Ax\|_2 = 1$

4) $\text{cond}(A) = \max \|Ax\|$

Si $A = \alpha I \rightarrow \text{cond}(A) = 1$

$\det(A) = \alpha^m$ Si α es pequeño $\rightarrow \det(A)$ es muy chico.

$$\alpha x_1 = b_1$$

$$x_1 = b_1/\alpha$$

$$\alpha x_2 = b_2$$

\vdots → No tengo problemas

$$x_i = b_i/\alpha$$

númericos.

$$\alpha x_m = b_m$$

los problemas numéricos se reflejan mejor en que $\text{cond}(A)$ sea grande más que en que $\det(A)$ sea pequeño

5) Si A es diagonal $\rightarrow \text{cond}(A) = \frac{\max_i |d_{ii}|}{\min_i |d_{ii}|}$

Ejemplo: $A = \begin{bmatrix} 0,5 & 0 \\ -2 & 3 \\ 0 & -5 \end{bmatrix}$ $\text{cond}(A) = \frac{5}{0,5} = 10$

Error relativo de una solución aproximada

$Ax = b$, x solución exacta, \hat{x} solución aproximada.

Residuo: $r = b - A\hat{x}$

$$= Ax - A\hat{x}$$

$$= A(x - \hat{x})$$

Si A es invertible: $A^{-1}r = x - \hat{x}$

$$\rightarrow \|x - \hat{x}\| = \|A^{-1}r\| \leq \|A^{-1}\| \|r\| \quad (1)$$

$$Ax = b$$

$$\rightarrow \|b\| = \|Ax\| \leq \|A\| \|x\| \quad (2)$$

$$\Rightarrow \frac{\|x - \hat{x}\|}{\|x\|} \leq \|A^T\| \|r\| \frac{\|A\|}{\|b\|}$$

$$\rightarrow \frac{\|x - \hat{x}\|}{\|x\|} \leq \text{cond}(A) \frac{\|r\|}{\|b\|} \quad (3)$$

↑ Error relativo (en norma) de la sol. aprox. \hat{x} .

Lota inferior:

$$r = A(x - \hat{x})$$

$$\rightarrow \|r\| \leq \|A\| \|x - \hat{x}\| \quad (4)$$

$$x = A^{-1}b \rightarrow \|x\| \leq \|A^{-1}\| \|b\| \quad (5)$$

$$\Rightarrow \frac{1}{\|A\| \|A^{-1}\|} \frac{\|r\|}{\|b\|} \leq \frac{\|x - \hat{x}\|}{\|x\|} \rightarrow \frac{1}{\text{cond}(A)} \frac{\|r\|}{\|b\|} \leq \frac{\|x - \hat{x}\|}{\|x\|} \quad (6)$$

Si $K(A) = \text{cond}(A)$

$$\frac{1}{K(A)} \frac{\|r\|}{\|b\|} \leq \frac{\|x - \hat{x}\|}{\|x\|} \leq K(A) \frac{\|r\|}{\|b\|}$$

Obs:

a) Si $K(A)$ no es muy grande entonces, si el residuo es pequeño se tiene que el error relativo (en norma) de la sol. aprox. \hat{x} es pequeño $\Rightarrow \hat{x}$ está próximo a x que es la solución exacta.


b) Si $K(A) \gg 1$ entonces, aunque el residuo sea pequeño, puede pasar que \hat{x} esté lejos de la sol. exacta.

c) Wilkinson: Escalierización gaussiana con pivoteo genera soluciones \hat{x} que tienen residuos pequeños

Si $K(A)$ es muy grande (relacionado con $\frac{1}{\epsilon_M}$) entonces

dicimos que el problema de resolver $Ax=b$ está mal condicionado

Idea general: N° de condición de un problema.



$K(P) = \text{coeficiente de magnificación de los errores relativos en la entrada para obtener los errores relativos en la salida}$

$$\frac{\|s - \hat{s}\|}{\|s\|} \leq K(P) \frac{\|d - \hat{d}\|}{\|d\|}$$

EQUACIONES NO LINEALES:

Caso Escalar: $f(x)=0$ $f: \mathbb{R} \rightarrow \mathbb{R}$. f continua.

Método de bipartición

Bolzano:

Si $f(a) - f(b) < 0 \rightarrow \exists x_0 \in [a, b] / f(x_0) = 0$.

condiciones de parada: a) encontramos un $x / |f(x)| < \text{tolerancia}_1$
(casi una raíz)

y/o b) el intervalo en el que está la raíz es suficientemente pequeño.
($b - a < \text{tolerancia}_2$)

a. b / $f(a) \cdot f(b) < 0$

1) Si $b - a < \text{tol}_2$ STOP

2) $m = \frac{a+b}{2}$ Calcular $f(m)$

si $|f(m)| < tol$ STOP

3) if $f(a), f(m) < 0$

$$b = m$$


else $a = m$

Volver a 1.

Si se toma en cada paso m como estimación de la raíz x^* entonces el error se reduce en por lo menos la mitad en cada iteración.

Ejemplo:

$$\left(\frac{x}{2}\right)^2 - \sin x = 0$$



$$I_0 = [1.8, z] = [a_0, b_0]$$

k	a_k	b_k	m_k	$f(m_k)$
1	1,8	2	1,9	< 0
2	1,9	2	1,95	> 0
3	1,9	1,95	1,925	< 0
4	1,925	1,95	1,9375	> 0
5	1,925	1,9375	1,93125	< 0
6	1,93125	1,9375	1,934375	> 0

Después de 6 iteraciones tenemos que $x^* \in (1,93125, 1,934375)$

con intervalo de largo

$$0,2 \cdot 10^{-6} = 0,003125$$

Obs: $\log_{10} \frac{1}{2} = 3,3$

Cada 3,3 iteraciones el error relativo se divide por 10

Como EM (en Matlab) $\approx 2,2 \cdot 10^{-16}$

en $16 \cdot 3,3 \approx 52$ iteraciones \rightarrow a estar en un error relativo del orden de EM. si el error relativo inicial < 1

MÉTODO DE BISECCIÓN.

$$f(x) = 0$$

x^* es la raíz de f a la que converge m^k

Si ϵ_i es el error en la iteración i $\epsilon_i = m_i - x^*$

entonces para biseción tenemos $\frac{|\epsilon_{i+1}|}{|\epsilon_i|} \approx 1/2$

Def: Si $x_1, x_2, \dots, x_m \rightarrow x$, $\epsilon_m = x_m - x$

$$\lim_{m \rightarrow \infty} \frac{|\epsilon_{m+1}|}{|\epsilon_m|^r} = c \quad (c > 0)$$

decimos que la solución (o el método que la genera) tiene orden de convergencia r y c se llama constante asintótica del error

Si $r=1$ decimos que la convergencia es lineal

Si $r>1$ " " " " " superlineal

Si $r=2$ " " " " " cuadrática

Si $r=3$ " " " " " cúbica

Ejemplos: a) $\left(\frac{1}{2}\right)^n \rightarrow 0$ con convergencia lineal

$$\lim_{n \rightarrow \infty} \frac{|(1/2)^{n+1} - 0|}{|(1/2)^n - 0|^1} = \lim_{n \rightarrow \infty} \frac{1/2^{n+1}}{1/2^n} = 1/2 \rightarrow \begin{cases} r=1 \\ c=1/2 \end{cases}$$

b) $\left(\frac{3}{7}\right)^{2^n} \rightarrow 0 \quad (\alpha^n)^\gamma = \alpha^{n\gamma}$

$$\lim_{n \rightarrow \infty} \frac{\left|\left(\frac{3}{7}\right)^{2^{n+1}} - 0\right|}{\left|\left(\frac{3}{7}\right)^{2^n} - 0\right|^2} = \lim_{n \rightarrow \infty} \frac{\left(\frac{3}{7}\right)^{2^{n+1}}}{\left(\left(\frac{3}{7}\right)^{2^n}\right)^2} = \lim_{n \rightarrow \infty} \frac{\left(\frac{3}{7}\right)^{2^{n+1}}}{\left(\frac{3}{7}\right)^{2^{n+1}}} = 1$$


$r=2 \quad c=1 \rightarrow$ Convergencia cuadrática.

c) si $0 < \beta < 1$ β^{3^n} tiene convergencia cuadrática a 0.

$$\lim_{n \rightarrow \infty} \frac{\beta^{3^{n+1}}}{(\beta^{3^n})^3} = 1 \rightarrow \begin{cases} r=3 \\ c=1 \end{cases}$$

MÉTODO DE NEWTON.

Supongamos que x_i es una aproximación a la raíz x^* de $f(x) = 0$.



En vez de "cortar" el gráfico de la función con el eje ox , "cortamos" la recta tangente a ese gráfico en el punto $(x_i, f(x_i))$

La pendiente de esa recta es $m = f'(x_i)$.


Recta tangente : $y - f(x_i) = f'(x_i)(x - x_i)$

Cortamos con ox ($y = 0$) $-f(x_i) = f'(x_i)(x - x_i)$

$$\rightarrow x = x_i - \frac{f(x_i)}{f'(x_i)} \Rightarrow x_{i+1} = x_i - \frac{f(x_i)}{f'(x_i)}$$

Método de Newton.

Ejemplo: $f(x) = x^2 - 2$ $x_0 = 1$



$$f' = 2x$$

$$x_{i+1} = x_i - \frac{(x_i^2 - 2)}{2x_i} = \frac{1}{2} \left(x_i + \frac{2}{x_i} \right)$$

$$x_1 = \frac{3}{2}$$

$$x_2 = \frac{17}{12}$$

$$x_3 = \frac{577}{408} \approx 1.414216$$

$$\sqrt{2} = 1.414214\dots$$

Si el Método de Newton converge, en general converge muy rápido con convergencia cuadrática.

Desarrollamos por Taylor alrededor de x_i

$$\rightarrow f(x) = f(x_i) + f'(x_i)(x - x_i) + \frac{1}{2} f''(c)(x - x_i)^2 \quad c \in [x, x_i]$$

$$\text{Si } x = x^* \rightarrow 0 = f(x_i) + f'(x_i)(x^* - x_i) + \frac{1}{2} f''(c)(x^* - x_i)^2 \\ f(x^*) = 0$$

$$0 = \left(\frac{f(x_i)}{f'(x_i)} + (x^* - x_i) + \frac{1}{2} \frac{f''(c)}{f'(x_i)} (x^* - x_i)^2 \right)$$

$$\rightarrow x_{i+1} - x^* = \frac{1}{2} \frac{f''(c)}{f'(x_i)} (x_i - x^*)^2$$


$$\rightarrow e_{i+1} = \frac{1}{2} \frac{f''(c)}{f'(x_i)} e_i^2$$

(si f' es continua en $x^* \rightarrow f'(x_i) \rightarrow f'(x^*)$)

Si suponemos que $f'(x^*) \neq 0$ (o sea x^* es raíz simple def)

$$\rightarrow \lim_{i \rightarrow \infty} \frac{|e_{i+1}|}{e_i^2} = \frac{1}{2} \frac{f''(x^*)}{f'(x^*)} = c \quad (\text{supuse } f' \text{ continua en } x^*)$$

Ejemplo:



$$x_{i+1} = x_i - \frac{x_i^2}{2x_i} = x_i - \frac{x_i}{2} = \frac{x_i}{2} \quad \rightarrow x_{i+1} = \frac{x_i}{2}$$


$$x_0 = 1, x_1 = \frac{1}{2}, x_2 = \frac{1}{4}, \dots, x_n = \frac{1}{2^n} \quad x_n \rightarrow 0 \text{ linealmente.}$$

No hay convergencia cuadrática porque 0 no es raíz simple de $f(x) = x^2$.

Ejemplo: $f(x) = \operatorname{Arctg}(x)$

$$f'(x) = \frac{1}{1+x^2}$$

$$x^* = 0$$



$$x_{n+1} = x_n - \frac{\operatorname{arctg}(x_n)}{1}$$

$$x_{n+1} = x_n - (1+x_n^2) \operatorname{arctg}(x_n)$$

$$\text{Si } x_0 = \frac{\pi}{4} = 0,7854 \rightarrow x_1 = -0,2911 \rightarrow x_2 = 0,0162$$

$$\rightarrow x_3 = -2,8 \cdot 10^{-6} \rightarrow x_4 = 1,49 \cdot 10^{-17}$$

$$\text{Si } x_0 = \frac{\pi}{2} = 1,57 \rightarrow x_1 = -1,91 \rightarrow x_2 = 3,15 \rightarrow x_3 = -10,64$$


$\rightarrow x_4 = 158 \rightarrow x_5 = -3,9 \cdot 10^4$ no converge.

En el valor crítico



$\gamma = 1,3415$ para este valor pasa de un paso al siguiente de x a $-x$ y viceversa

Ejemplo: $f(x) = \operatorname{sg}(x-a)\sqrt{|x-a|}$



si el valor inicial x_0 no está próximo a la raíz \rightarrow no podemos asegurar la convergencia.

si $0 < a < f' < b \rightarrow \exists$ un entorno de x^* tal que si $x_0 \in$
a ese entorno hay convergencia a x^*

16/09

MÉTODO DE LA SECANTE



En el método de newton $x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$
 $f'(x_n) \leftarrow$ pendiente de la recta

Esto surge de la intersección de la recta por $(x_n, f(x_n))$ y pendiente $f'(x_n)$ con el eje \bar{Ox} .

Ahora usamos la recta o secante cuya pendiente es :

$$m = \frac{f(x_n) - f(x_{n-1})}{x_n - x_{n-1}}$$

$$x_n - x_{n-1}$$

→ Método de la secante:

$$x_{n+1} = x_n - \frac{f(x_n)(x_n - x_{n-1})}{f(x_n) - f(x_{n-1})}$$

- Obs:
- 1) No calculo derivadas
 - 2) Cada iteración me cuesta 1 evaluación de f .
 - 3) Necesito 2 valores iniciales x_0, x_1 .

Ejemplo: calcular $\sqrt{15}$

$$x^2 - 15 = 0$$

$$\text{Secante: } x_{n+1} = x_n - \frac{(x_n^2 - 15)(x_n - x_{n-1})}{x_n^2 - x_{n-1}^2}$$

$$\rightarrow x_{n+1} = x_n - \frac{(x_n^2 - 15)}{x_n + x_{n-1}}$$

$$x_0 = 3$$

$$x_1 = 4$$

$$\rightarrow x_2 = 3,857142857$$

$$x_3 = 3,8729\dots$$

$$x_4 = 3,872983347$$

$$\text{En matlab } \text{sqrt}(15) = 3,87298834620742.$$

Teorema: Si la sucesión x_n del método de la secante converge a una raíz simple, x^* de f y f'' es const en x^*

→ hay convergencia superlineal con $r \neq \phi = \text{num de oro}$

$$\phi = \frac{\sqrt{5} + 1}{2} \approx 1,618$$

$$\text{y constante } c = |f''(x^*)| / 2|f'(x^*)|^{1/2}$$

o sea si el error es $e_n = x_n - x^*$

$$\text{se tiene } \lim_{n \rightarrow \infty} \frac{|e_{n+1}|}{|e_n|^{\phi}} = c.$$

$$\text{Se puede probar: } e_{n+2} = k e_{n+1} \cdot e_n$$

$$\sqrt{n} = \log(e_n) \rightarrow \sqrt{n+2} = \log k + \sqrt{n+1} + \sqrt{n}.$$

Ecuación homogénea

$$J_{n+2} - J_{n+1} - J_n = 0 \quad (\text{sucesión de Fibonacci})$$

Si buscamos soluciones de la forma $J_n = \lambda^n$

$$\rightarrow \lambda^{n+2} - \lambda^{n+1} - \lambda^n = 0.$$

$$\lambda^n(\lambda^2 - \lambda - 1) = 0 \quad P(\lambda) = \lambda^2 - \lambda - 1$$

$$\lambda = \frac{1 \pm \sqrt{1+4}}{2} = \frac{1 \pm \sqrt{5}}{2}$$

$$\rightarrow J_n = \alpha \left(\frac{1+\sqrt{5}}{2} \right)^n + \beta \left(\frac{1-\sqrt{5}}{2} \right)^n$$

$$\frac{J_{n+1}}{J_n} = \frac{1+\sqrt{5}}{2}$$


Convergencia: Resultados análogos al Método de Newton.

Método de Regula Falsi: derivado de la secante pero forcamos la convergencia. (perjuicio posible: podemos perder la superlinealidad)

$$x_0, x_1 \quad / \quad f(x_0) \cdot f(x_1) < 0$$

aplico el método de la secante entre x_n y x_m / m es el máximo índice $< n / f(x_n) \cdot f(x_m) < 0$

$$x_{n+1} = x_n - \frac{f(x_n)(x_n - x_m)}{f(x_n) - f(x_m)}$$



SISTEMAS NO LINEALES DE ECUACIONES

$$f: \mathbb{R}^n \rightarrow \mathbb{R}^n \quad f(x) = 0$$

$$f_1: \mathbb{R}^n \rightarrow \mathbb{R}$$

$$f_2: \mathbb{R}^n \rightarrow \mathbb{R}$$

:

$$x = (x_1, \dots, x_n)$$

$$f(x) = \begin{pmatrix} f_1(x) \\ f_2(x) \\ \vdots \end{pmatrix} = \begin{pmatrix} f_1(x_1, \dots, x_n) \\ f_2(x_1, \dots, x_n) \\ \vdots \end{pmatrix}$$

Método de Newton - Raphson para sistemas.

Supongamos que x^* es una solución del sistema ($f(x^*) = \vec{0}$)

Si tenemos al iterando $x^{(k)}$ y suponemos que está cerca de x^* entonces desarrollando por Taylor alrededor de $x^{(k)}$:

$$f_1(x) = f_1(x^{(k)}) + df_1 \Big|_{x=x^{(k)}} + \text{términos de } 2^{\circ} \text{ orden.}$$

$$df_1 \Big|_{x=x^{(k)}} = \frac{\partial f_1(x^{(k)})}{\partial x_1} (x_1 - x_1^{(k)}) + \frac{\partial f_1(x^{(k)})}{\partial x_2} (x_2 - x_2^{(k)}) + \dots$$

$$+ \frac{\partial f_1(x^{(k)})}{\partial x_n} (x_n - x_n^{(k)})$$

$$\begin{aligned} \text{términos de } 2^{\circ} \text{ orden} &= \frac{1}{2} \left(\sum_{i=1}^{i=n} \frac{\partial^2 f_1}{\partial x_i^2} (x_i - x_i^{(k)})^2 \right) \\ &+ 2 \sum_{i < j} \frac{\partial^2 f_1}{\partial x_i \partial x_j} (x_i - x_i^{(k)}) (x_j - x_j^{(k)}) \end{aligned}$$

$$x + \theta(x - x^{(k)})$$

$$0 \leq \theta \leq 1$$

dejando de lado los términos de segundo orden

$$f_1(x) \approx f_1(x^{(k)}) + \frac{\partial f_1(x^{(k)})}{\partial x_1} (x_1 - x_1^{(k)}) + \dots + \frac{\partial f_1(x^{(k)})}{\partial x_n} (x_n - x_n^{(k)})$$

:

$$f_n(x) \approx f_n(x^{(k)}) + \frac{\partial f_n(x^{(k)})}{\partial x_1} (x_1 - x_1^{(k)}) + \dots + \frac{\partial f_n(x^{(k)})}{\partial x_n} (x_n - x_n^{(k)})$$

J = matriz jacobiana.

$$J(x^{(k)})_{ij} = \frac{\partial f_i(x^{(k)})}{\partial x_j} \quad \text{Matriz } n \times n \text{ numérica.}$$

$$\rightarrow f(x) = \begin{pmatrix} f_1(x) \\ \vdots \\ f_n(x) \end{pmatrix} \approx f(x^{(k)}) + J(x^{(k)}) \begin{pmatrix} x_1 - x_1^{(k)} \\ \vdots \\ x_n - x_n^{(k)} \end{pmatrix}$$

$$\rightarrow f(x) \approx f(x^{(k)}) + J(x^{(k)})(x - x^{(k)}) \quad (x \text{ y } x^{(k)} \text{ son vectores columnas})$$

El nuevo iterado $x^{(k+1)}$ se halla resolviendo (o es la solución del sistema)

$$J_f(x^{(k)}) \cdot (x - x^{(k)}) = -f(x^{(k)})$$

18/09.

Dado $x^{(k)}$ calculamos $x^{(k+1)}$ de forma tal que:

$$J_f(x^{(k)})(x^{(k+1)} - x^{(k)}) = -f(x^{(k)})$$

$$\text{o bien: } x^{(k+1)} = x^{(k)} - [J_f(x^{(k)})]^{-1} f(x^{(k)})$$

El caso escalar $f(x) = 0$

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)} \quad x_{n+1} = x_n - [f'(x_n)]^{-1} f(x_n)$$


En la práctica si $s^{(k)} = x^{(k+1)} - x^{(k)}$ ($s^{(k)}$ es el peso del Método de Newton)

$$x^{(k+1)} = x^{(k)} + s^{(k)}$$

1) Resuelvo el sistema: $J_f(x^{(k)}) s^{(k)} = -f(x^{(k)})$

$$2) x^{(k+1)} = x^{(k)} + s^{(k)}$$

Ejemplo: $f(x) = \begin{pmatrix} x_1 + 2x_2 - 2 \\ x_1^2 + 4x_2^2 - 4 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$



$$J_f(x) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2x_1 & 8x_2 \end{bmatrix}$$

$$x^{(0)} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \quad f(x^{(0)}) = \begin{pmatrix} 3 \\ 13 \end{pmatrix} \quad J_f(x^{(0)}) = \begin{bmatrix} 1 & 2 \\ 2 & 16 \end{bmatrix}$$

$$x^{(1)} = x^{(0)} + s^{(0)} = \begin{pmatrix} -0,83 \\ 1,42 \end{pmatrix} ; \quad \begin{bmatrix} 1 & 2 \\ 2 & 16 \end{bmatrix} s^{(0)} = \begin{pmatrix} -3 \\ 13 \end{pmatrix} \rightarrow s^{(0)} = \begin{bmatrix} -1,83 \\ -0,58 \end{bmatrix}$$

$$f(x^{(1)}) = \begin{pmatrix} 0 \\ 4,72 \end{pmatrix} \quad J_f(x^{(1)}) = \begin{bmatrix} 1 & 2 \\ -1,67 & 11,3 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 2 \\ -1,67 & 11,3 \end{bmatrix} s^{(1)} = \begin{pmatrix} 0 \\ -4,72 \end{pmatrix} \rightarrow s^{(1)} = \begin{pmatrix} 0,64 \\ -0,32 \end{pmatrix}$$

$$x^{(2)} = x^{(1)} + s^{(1)} = \begin{pmatrix} -0,19 \\ 1,10 \end{pmatrix}, \text{ iterando converge a } \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

Costo de la iteración de Newton

1) Cálculo de la jacobiana $J_f(x^{(k)})$

Evaluación de n^2 funciones escalares $\left(\frac{\partial f_i(x^{(k)})}{\partial x_j}\right)$

2) Resolución del sistema $O(n^3)$

Obs: 1) Se puede implementar que la J_f no se recalcula en cada iteración si no cada r pasos.

2) Si no dispongo de las derivadas parciales para la jacobiana puedo hallar una jacobiana numérica aproximada. (equivale a aproximar la derivada por cociente incremental)

$$\frac{\partial f_i(x^{(k)})}{\partial x_j} \approx \frac{f_i(x^{(k)} + h e_j) - f_i(x^{(k)})}{h}$$

$$e_j = \begin{pmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \end{pmatrix} \quad \text{← posición } j$$

MÉTODO TIPO SECANTE

$$\text{Escalar: } x_{n+1} = x_n - \frac{f(x_n)}{\left(\frac{f(x_n) - f(x_{n-1})}{x_n - x_{n-1}} \right)} = m$$

$$x_{n+1} = x_n - m^{-1} f(x_n)$$

$$m \text{ verifica: } m \cdot (x_n - x_{n-1}) = f(x_n) - f(x_{n-1})$$

Quisiéramos una matriz M tal que: $M_m (x^{(m)} - x^{(m-1)}) = f(x^{(m)}) - f(x^{(m-1)})$.

$$\rightarrow x^{(m+1)} = x^{(m)} - M_m^{-1} f(x^{(m)}) \quad (M_m s^{(m)} = -f(x^{(m)}))$$
$$x^{(m+1)} = x^{(m)} + s^{(m)}$$

→ actualización de la matriz M_{n+1}

$$M_{n+1} (x^{(n+1)} - x^{(n)}) = f(x^{(n+1)}) - f(x^n) \quad (\text{I})$$

M_{n+1} es una matriz $n \times n$.

Tengo n^2 incógnitas

Tiene que verificar n ecuaciones.

Broyden dice la M_{n+1} tal que verifica (I)

y $\|M_n - M_{n+1}\|_{\text{Fro}}$ sea mínima.

$$\|A\|_{\text{Fro}} = \sqrt{\sum_i \sum_j |a_{ij}|^2}$$

$$M_i = M_{i-1} + \frac{[f(x^{(i)}) - f(x^{(i-1)})] - M_{i-1}(x^{(i)} - x^{(i-1)})}{\|x^{(i)} - x^{(i-1)}\|_2^2} (x^{(i)} - x^{(i-1)})^T$$

(perturbación de rango 1 de la anterior).

Método de Broyden (tipo secante)

$x^{(0)}$ valor inicial

B_0 (por ejemplo una aproximación a $J(x^{(0)})$)

for $k = 0, 1, 2, \dots$

$$\text{Resolver } B_k s^{(k)} = -f(x^{(k)})$$

$$x^{(k+1)} = x^{(k)} + s^{(k)}$$

$$J^{(k)} = f(x^{(k+1)}) - f(x^{(k)})$$

$$B_{k+1} = B_k + (J^{(k)} - B_k s^{(k)}) s_k^T / s_k^T s_k$$

Ejemplo anterior:

$$x^{(0)} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \quad f(x^{(0)}) = \begin{pmatrix} 3 \\ 13 \end{pmatrix} \quad B_0 = J(x^{(0)}) = \begin{bmatrix} 1 & 2 \\ 2 & 16 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 2 \\ 2 & 16 \end{bmatrix} s^{(0)} = \begin{pmatrix} -3 \\ 13 \end{pmatrix} \rightarrow s^{(0)} = \begin{pmatrix} -1.83 \\ -0.058 \end{pmatrix}$$

$$x^{(1)} = x^{(0)} + s^{(0)} = \begin{pmatrix} -0.83 \\ -1.42 \end{pmatrix}$$

$$f(x^{(1)}) = \begin{pmatrix} 0 \\ -4,72 \end{pmatrix} \quad J^{(0)} = f(x^{(1)}) - f(x^{(0)}) = \begin{pmatrix} -3 \\ -8,28 \end{pmatrix}$$

$$B_1 = \begin{bmatrix} 1 & 2 \\ 2 & 16 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ -2,34 & -0,74 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ -0,34 & 15,28 \end{bmatrix}$$

$$B_1 s^{(1)} = \begin{pmatrix} 0 \\ -4,72 \end{pmatrix}$$

$$s^{(1)} = \begin{pmatrix} 0,59 \\ -0,30 \end{pmatrix} \quad x^{(2)} = x^{(1)} + s^{(1)} = \begin{pmatrix} -0,24 \\ 1,12 \end{pmatrix}$$

$$B_2 = \begin{bmatrix} 1 & 2 \\ 1,12 & \end{bmatrix} \quad \text{converge a}$$

23/09.

MÉTODO ITERATIVO GENERAL (MIG)

$$(Parecido a Ax=b \rightarrow x^{(k+1)} = Bx^{(k)} + f)$$

En vez de plantear $f(x)=0$ vamos a considerar una ecuación equivalente $x=g(x)$

Consideraremos métodos iterativos de punto fijo : $x_{n+1} = g(x_n)$

con cierta condición inicial x_0 .

(puede ser más general $x_{n+1} = g(x_n, x_{n-1})$)

$$\text{Ejemplo : } f(x) = \sin x - x^2 = 0 \rightarrow \begin{cases} x = g_1(x) = \sqrt{\sin x} \\ x = g_2(x) = \arcsin(x^2) \\ x = g_3(x) = \sin x - x^2 + x \end{cases}$$

También $x = x - \beta f(x)$ con β cte apropiado.

Teorema 1. Si $g: [a,b] \rightarrow [a,b]$ continua

$$\rightarrow \exists x^* \in [a,b] / x^* = g(x^*)$$

Dem: Si $g(a) = a \rightarrow x^* = a$ verifica.

$$\text{Si } g(b) = b \rightarrow x^* = b \quad "$$

Si no es así $g(a) > a$ y $g(b) < b$.

$$\rightarrow F(x) = g(x) - x \text{ es continua en } [a,b], F(a) > 0 \\ F(b) < 0$$

Bolzano.

$$\rightarrow \exists x^* \in (a,b) / F(x^*) = 0 \rightarrow g(x^*) = x^*$$

Def: $g: A \subseteq \mathbb{R}^n \rightarrow \mathbb{R}^n$ se dice contractiva si $\exists k, 0 \leq k < 1$

$$\text{tal que: } \|g(x) - g(x')\| \leq k \|x - x'\| \quad \forall x, x' \in A$$

Teorema 2. Si $g: [a,b] \rightarrow [a,b]$ contractiva entonces:

a) La sucesión generada por el MFG ($x_{n+1} = g(x_n)$)
 $x_0 / x_0 \in [a,b]$)

converge a un punto fijo de g .

b) \exists un único punto fijo α de g en $[a,b]$.

$$c) |\alpha - x_{n+1}| \leq k |\alpha - x_n|$$

Dem: a) se prueba que la sucesión x_n es de Cauchy (en $[a,b]$)

$x_n \rightarrow \alpha$, como $x_{n+1} = g(x_n)$, $\lim g(x_n) \xleftarrow{g \text{ cont}} \alpha = g(\alpha)$, α es punto fijo de g

b) Supongamos existen 2 puntos fijo de g en $[a,b]$

$$g(\alpha) = \alpha$$

$$g(\beta) = \beta$$

$$|\alpha - \beta| = |g(\alpha) - g(\beta)| \leq k |\alpha - \beta| < |\alpha - \beta| \text{ absurdo}$$


$$c) |\alpha - x_{n+1}| = |g(\alpha) - g(x_n)| \leq k |\alpha - x_n|$$

Teorema 3: Si $g: [a,b] \rightarrow \mathbb{R}$ tiene derivada continua y

$\alpha \in [a,b]$ es un punto fijo de g entonces

i) si $|g'(\alpha)| < 1$, la iteración de MFG converge a α
siempre que x_0 sea lo suficientemente próximo a α

ii) si $|g'(x)| > 1$, la iteración de M/G no converge a x ($x_0 \neq x$)




Dam: i) Por la continuidad de g' \exists un intervalo B $B \subset [a, b]$, de centro x , tal que $|g'(x)| \leq k < 1 \quad \forall x \in B$
 $(g'(x) < 1)$

Por Lagrange: $|g(x') - g(x)| = |g'(c) \cdot (x' - x)| \quad c \in [x, x']$
 $\rightarrow |g(x') - g(x)| = |g'(c)| |x' - x| \leq k |x' - x|$
 $\rightarrow g$ es contractiva en B .

Veamos que $g(x) \in B$ si $x \in B$

$$|g(x) - x| = |g(x) - g(x')| \leq k |x - x'|$$



$\rightarrow g(x)$ está más próximo a x que a a
 $(k < 1) \rightarrow g(x) \in B$

\rightarrow Vale el teorema 2 donde k es una cota de g' en un entorno de x .

ii) Si $|g'(x)| > 1 \rightarrow \exists B / |g'(x)| \geq k > 1$


$$|g(x') - g(x)| \geq k|x - x'| \quad \forall x, x' \in B.$$

Entonces si $x_n \in B$

$$|x_{n+1} - x| = |g(x_n) - g(x)| \geq k|x_n - x| \geq k(k|x_{n-1} - x|)$$

$$\dots \geq \underbrace{k^{n+1}}_{\downarrow \text{too}} |x_0 - x| \rightarrow x_{n+1} \text{ no converge a } x.$$

Ejemplo: $f(x) = \sin x - x^2 = 0$



$$g_1(x) = \sqrt{\sin x}$$

$$|g_1'(x)| = \left| \frac{1}{2} \frac{\cos x}{\sqrt{\sin x}} \right| < 0,45 \rightarrow g_1 \text{ sirve.} \quad (k=0,45)$$

$$g_2(x) = \arcsin x^2 \quad |g_2'(x)| = \left| \frac{1}{\sqrt{1-x^4}} x^2 \right| > 2 \text{ en } (0,8, 0,9) \rightarrow g_2 \text{ no sirve.}$$

$$g_3(x) = \sin x - x^2 + x \quad |g_3'(x)| = |\cos x - 2x + 1| < 0,18 \text{ en } (0,8, 0,9) \rightarrow g_3 \text{ sirve.} \quad (k=0,18)$$

Criterio de parada.

1) Si $\frac{|x_{n+1} - x_n|}{|x_{n+1}|} < \varepsilon$ ponemos fin a las iteraciones

2) Si estamos en el MIG y tenemos el valor de k (o una estimación de él)

$$x_n - x = -g(x_n) + g(x_{n-1}) + g(x_n) - g(x)$$

$$\begin{aligned}\rightarrow |x_n - \alpha| &\leq |g(x_{n-1}) - g(x_n)| + |g(x_n) - g(\alpha)| \\ |x_n - \alpha| &\leq k|x_{n-1} - x_n| + k|x_n - \alpha| \\ \rightarrow |x_n - \alpha| &\leq \frac{k}{1-k} |x_n - x_{n-1}|\end{aligned}$$

Entonces si paramos cuando $\frac{k}{1-k} |x_n - x_{n-1}| < \varepsilon$.

α tiene que el error real (absoluto) es $< \varepsilon$.

Método de Newton:

$$x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)} \quad g(x) = x - \frac{f(x)}{f'(x)}$$

$$\text{Si } f(x) = 0 \quad (g(\alpha) = 0) \quad g'(x) = 1 - \frac{[f'(x)]^2 - f(x)f''(x)}{[f'(x)]^2}$$

$$g'(x) = 1 - \frac{(f'(x))^2 - f(x)f''(x)}{(f'(x))^2} = 0.$$

→ En un entorno de α g es una contracción.

→ Si x_0 está prox. a α — Newton converge.

$$\begin{cases} y' = f(x, y) \\ y(x_0) = y_0 \end{cases}$$

MÉTODO DE EULER:

Tenemos un intervalo $[x_0, a]$ y lo dividimos en subintervalos

$$x_0 < x_1 < x_2 < \dots < x_n < \dots < a$$

La solución exacta es $y(x)$

Si desarrollamos por Taylor:

$$y(x+h) = y(x) + y'(x)h + y''(x)\frac{h^2}{2} + y'''(x)\frac{h^3}{6} + \dots$$

O bien $y(x+h) = y(x) + y'(x)h + y''(c)\frac{h^2}{2}$ con $c \in [x, x+h]$

$$y'(x) = f(x, y(x))$$

$$\rightarrow y(x+h) = y(x) + hf(x, y(x)) + y''(c)\frac{h^2}{2} \quad c \in [x, x+h]$$

Si despreciamos $y''(c)\frac{h^2}{2}$ (error de truncamiento) tendríamos:

$$y(x+h) \approx y(x) + hf(x, y(x)) ; \quad y(x_n+h) \approx y(x_n) + hf(x_n, y(x_n))$$

Si a su vez y_n es una aproximación a $y(x_n)$ nos queda para y_{n+1} la aproximación:


$$y_{n+1} = y_n + hf(x_n, y_n), \quad y_0 \text{ lo tenemos por la condición inicial}$$

$$y_1 = y_0 + hf(x_0, y_0)$$

$$y_2 = y_1 + hf(x_1, y_1)$$

⋮

Graficamente:



$$y'(x_0) = f(x_0, y_0)$$

$$y_1 = y_0 + hf(x_0, y_0) \quad \frac{y_1 - y_0}{x_1 - x_0} = f(x_0, y_0)$$

$$y_2 = y_1 + hf(x_1, y_1) \quad \frac{y_2 - y_1}{x_2 - x_1} = f(x_1, y_1)$$

y es otra solución de
 $y' = f(x, y)$ que pasa por (x_1, y_1)

Def. Error global en $x_n = y(x_n) - y_n$ donde $y(x)$ es la solución exacta de la ecuación evaluada en x_n e y_n es el resultado obtenido por el método correspondiente a $x=x_n$.

Error local en $x_n = y(x_{n+1}) - y_{n+1}$ donde $y(x_n)$ es la solución exacta de $\begin{cases} y' = f(x, y) \\ y(x_n) = y_n \end{cases}$

En el método de euler el error local (o error de truncamiento) vale $\frac{y'''(c)h^2}{2} \quad c \in [x_n, x_{n+1}]$

Teorema: Bajo condiciones muy generales si error local = $\sigma(h^{p+1})$ entonces el error global = $\sigma(h^p)$

A p se lo llama orden de consistencia del método.

Decimos entonces que el método de euler es de orden 1

Veamos una fila de métodos con error local más chico:

$$* \quad y_{n+1} = y_n + h[A_1 f(x_n, y_n) + A_2 f(x_n + \alpha h, y_n + \alpha h f(x_n, y_n))]$$

Tenemos 3 parámetros: A_1, A_2, α (con $A_1=1$ y $A_2=0$)

→ Método de euler.

Vamos a imponer que el error local sea $\sigma(h^3)$

$$y(x+h) = y(x) + \underbrace{y'(x)h}_{f(x, y(x))} + \frac{y''(x)h^2}{2} + \frac{y'''(x)h^3}{6} + \dots$$

$$y'(x) = f(x, y(x)) \rightarrow y'' = f_x(x, y(x)) + f_y(x, y(x)) y'(x)$$

$$\rightarrow y''(x) = f_x(x, y(x)) + f_y(x, y(x)) f(x, y(x))$$

$$\rightarrow y(x_n+h) = y(x_n) + h f(x_n, y(x_n)) + \frac{h^2}{2} (f_x(x_n, y(x_n)) + f_y(x_n, y(x_n)) f(x_n, y(x_n))) + \frac{h^3}{6} y'''(x_n) + \dots$$

$$f(x_n + \frac{\Delta x}{2}, y_n + \frac{\Delta y}{2}) = \text{Taylor en } x_n, y_n$$

$$f(x_n, y_n) + f_x(x_n, y_n) \Delta x + f_y(x_n, y_n) \Delta y + o(h^2)$$

diferencial 2º.

* $\Rightarrow y_{n+1} = y_n + h(A_1 f(x_n, y_n) + A_2 f(x_n, y_n))$
 $+ h^2 (\alpha f_x(x_n, y_n) + \alpha f_y(x_n, y_n) \cdot f(x_n, y_n)) A_2 + o(h^3)$

Comparando e identificando todos los términos que pueda.

$$\begin{cases} A_1 + A_2 = 1 \\ \alpha A_2 = \frac{1}{2} \end{cases}$$

→ Si $\begin{cases} A_1 + A_2 = 1 \\ \alpha A_2 = \frac{1}{2} \end{cases}$ tenemos un método w/o error local
 $o(h^3)$

Son métodos de 2º orden

MÉTODO DE HEUN:


$$\alpha = 1 \rightarrow A_2 = \frac{1}{2}, A_1 = \frac{1}{2}$$

$$y_{n+1} = y_n + \frac{h}{2} \left(f(x_n, y_n) + f(x_n + h, y_n + h(f(x_n, y_n))) \right)$$

$$\alpha = \frac{1}{2} \rightarrow A_2 = 1, A_1 = 0$$

$$y_{n+1} = y_n + h f(x_n + \frac{h}{2}, y_n + \frac{h}{2} f(x_n, y_n))$$

es el método del punto medio o método de euler modificado



Hago euler con $h/2$
 $y_{n+1/2} = y_n + \frac{h}{2} f(x_n, y_n)$

Calculo $f(x_n + \frac{1}{2}, y_n + \frac{1}{2})$.

$$\rightarrow y_{n+1} = y_n + h f(x_n + \frac{1}{2}, y_n + \frac{1}{2})$$

Método de Heun.

$$y_{n+1} = y_n + \frac{h}{2} \left[f(x_n, y_n) + f(x_n + h, y_n + hf(x_n, y_n)) \right]$$

Es runge kutta de orden 2 (Error local $\Theta(h^3)$)

MATLAB: ode23, usa un método de este tipo.

Runge - kutta de orden 4: error local = $\Theta(h^5)$

$$y_{n+1} = y_n + \frac{h}{6} \left[k_1 + 2k_2 + 2k_3 + k_4 \right]$$

$$k_1 = f(x_n, y_n)$$

$$k_2 = f\left(x_n + \frac{h}{2}, y_n + \frac{h}{2}k_1\right)$$

$$k_3 = f\left(x_n + \frac{h}{2}, y_n + \frac{h}{2}k_2\right)$$

$$k_4 = f(x_n + h, y_n + hk_3)$$

ESTABILIDAD NUMÉRICA

$$\text{Ejemplo: } I_n = \int_0^1 \frac{x^n}{x+5} dx$$

$$I_0 = \int_0^1 \frac{1}{x+5} dx = L(x+5) \Big|_0^1 = L(6) - L(5) = L(6/5)$$

$$I_n = \int_0^1 \frac{x^n + 5x^{n-1} - 5x^{n-1}}{x+5} dx$$

$$I_n = \int_0^1 \frac{x^{n-1}(x+5) - 5x^{n-1}}{(x+5)} dx = \int_0^1 x^{n-1} dx - 5I_{n-1} = \frac{x^n}{n} \Big|_0^1 - 5I_{n-1}$$

$$I_n = \frac{1}{n} - 5I_{n-1}$$

Con matlab:

$$I_0 = 0,1823$$

$$I_1 = 0,0884$$

$$I_2 = 0,058.$$

:

$$I_{18} = 0,0087$$

$$I_{19} = 0,0092$$

$$I_{20} = 0,0042.$$

$$I_{21} = 0,0264$$

$$I_{22} = -0,0866$$

$$I_{23} = 0,43$$

$$I_{24} = -2,34$$

$$I_{25} = 11,74$$

$$I_{26} = -58,66$$

En cada paso el error anterior se multiplica por 5

→ en el paso n se habrá multiplicado por 5^n y por lo tanto la solución no queda acotada

Iteración hacia atrás:

$$I_{n-1} = \frac{1}{5} \left(\frac{1}{n} - I_n \right)$$

Estimación de I_{26} : considero que I_{26} es parecido a I_{25}

$$I_{26} \approx \frac{1}{26} - 5I_{26} \rightarrow I_{26} \approx \frac{1}{6,26} = 0,0064$$

$$I_{20} = 0,0080$$

$$I_{19} = 0,0084$$

:

$$I_4 = 0,0343$$

:

$$I_1 = 0,0884$$

$$I_0 = 0,1823$$

En cada iteración el error se divide por 5. Al final llega al I_0 exacto.

Aplicado a ecuaciones diferenciales:

Ejemplo: $\begin{cases} y' = 2y + xe^{-x} \\ y(0,1) = 0,1 \end{cases}$ solución exacta. $y(x) = -\frac{1}{3}e^{-x}$

$y_H: y' = 2y \rightarrow y_H = Ce^{2x}$

$y_P: y_P = Ae^{-x}$

$$\begin{aligned} A(-e^{-x}) &= 2Ae^{-x} + xe^{-x} \\ -3Ae^{-x} &= xe^{-x} \quad A = -\frac{x}{3} \end{aligned}$$

Sol. general:

$$y = Ce^{2x} - \frac{x}{3}e^{-x}$$

$$y(0) = C - \frac{x}{3} = -\frac{x}{3} \Rightarrow C = 0$$

Con el método de euler


$$\begin{cases} y_{n+1} = y_n + h(2y_n + e^{-xn}) \\ y_{n+1} = (1+2h)y_n + he^{-xn} \\ y_0 = -\frac{1}{3} \end{cases}$$

Si $h = \frac{1}{2}$

$$\begin{cases} y_{n+1} = 2y_n + 0,5e^{-xn} \\ y_0 = -\frac{1}{3} \end{cases}$$

$$y_1 = 2\left(-\frac{1}{3}\right) + 0,5 \cdot e^0 = -\frac{2}{3} + \frac{1}{2} = -\frac{2}{3} + \frac{1}{2} = -\frac{4+3}{6} = -\frac{1}{6}$$

$$y_2 = 2\left(-\frac{1}{6}\right) + 0,5 \cdot e^{-0,5} = -\frac{1}{3} + 0,5 \cdot e^{-0,5}$$



Hay un problema
de estabilidad
matemática.

Problema Test:

$$\begin{cases} y' = qy \\ y(0) = 1 \end{cases}$$

Def: Región de estabilidad de un método numérico.
= $\{z \in \mathbb{C} / z = qh \text{ y la sucesión } y_n \text{ generada por el método se mantiene acotada.}\}$

Región de estabilidad del método de Euler.

$$\begin{cases} y' = qy \\ y(0) = 1 \end{cases}$$

$$y_{n+1} = y_n + h f(x_n, y_n)$$

$$y_{n+1} = y_n + hg y_n \rightarrow \begin{cases} y_{n+1} = (1+hg)y_n \\ y_0 = 1 \end{cases}$$

$$\text{sol: } y_n = (1+hg)^n$$


$$y_{n+1} = (1+hg)y_n = (1+hg)(1+hg)y_{n-1} = \dots = (1+hg)^n$$

Si $|1+hg| > 1 \rightarrow y_n \text{ no queda acotada}$

Si $hg = z \rightarrow \text{región de estabilidad es } |1+z| \leq 1$

Recordemos: $|z - z_0| = \text{distancia del origen de } z \text{ al origen de } z_0$
 $[z+1 \mid z - (-1)]$

Si h es tal que hg no pertenece a ese círculo entonces la y_n no queda acotada



Teorema:

Consistencia + Estabilidad = convergencia



Se refiere a error local que tiende a 0.

la solución numérica refleja la solución exacta de la ecuación numérica.

Error local y Error Global

$$y' = f(x, y)$$

$$y(x_0) = y_0 \quad y(x) \text{ sol en } [x_0, a]$$

Supongamos el método dado por $y_{n+1} = y_n + h \Phi(x_n, y_n, h)$

Supongamos Φ es lipschitz en y : $\exists k > 0 /$

$$|\Phi(x, y, h) - \Phi(x, \bar{y}, h)| \leq k |y - \bar{y}|$$

Fijamos un paso $h = a - x_0$ y llamamos en al error global
 $en = y(x_n) - y_n$

Sea Z_n el error local del método tenemos:

$$y_{n+1} = y_n + h \Phi(x_n, y_n, h)$$

$$y(x_{n+1}) = y(x_n) + h \Phi(x_n, y(x_n), h) + Z_n$$

$$\text{restando: } en_{n+1} = en + h (\underbrace{\Phi(x_n, y(x_n), h) - \Phi(x_n, y_n, h)}_{en} + Z_n)$$

$$\rightarrow |en_{n+1}| \leq |en| + h k |y(x_n) - y_n| + |Z_n|$$

$$\rightarrow |en_{n+1}| \leq (1 + kh) |en| + |Z_n|$$

$$\text{Sea } \mathcal{Z} = \max |Z_n|$$

$$\rightarrow |en_{n+1}| \leq (1 + kh) |en| + \mathcal{Z}$$

$$\rightarrow |en_{n+1}| \leq (1 + kh) [(1 + kh) |en| + \mathcal{Z}] + \mathcal{Z}$$

$$\rightarrow |en_{n+1}| \leq (1 + kh)^2 |en| + \mathcal{Z} ((1 + kh) + 1)$$


continuando

$$|en_{n+1}| \leq (1 + kh)^{n+1} \underbrace{|en|}_{\mathcal{Z}} + \mathcal{Z} (1 + (1 + kh) + \dots + (1 + kh)^n)$$

$$\rightarrow |en_{n+1}| \leq \mathcal{Z} \frac{(1 + kh)^{n+1} - 1}{(1 + kh) - 1}$$

$$|e_{n+1}| \leq \frac{C}{h} \cdot \frac{1}{k} \left[(1+kh)^{n+1} - 1 \right] \leq \frac{C}{h} \frac{1}{k} \left(e^{(n+1)hk} - 1 \right)$$

Ahora observamos: $(1+\alpha)^{n+1} \leq e^{(n+1)\alpha}$



$$\rightarrow |e_{n+1}| \leq \frac{C}{h} \left(\frac{e^{kx_{n+1}} - 1}{k} \right) \leq \frac{C}{h} \left(\frac{e^{ka} - 1}{k} \right)$$

Def: El método se dice consistente si

$$\frac{\text{error local}}{h} \xrightarrow[h \rightarrow 0]{} 0$$

Por lo anterior si el método es consistente entonces el error global $e_n \rightarrow 0 \xrightarrow[h \rightarrow 0]{} (y_n - y(x_n))$

$$\text{Si } e_n = O(h^{P+1})$$

$\rightarrow e_n = O(h^P)$ y decimos que el orden de consistencia es P.

CASO EULER.

$$y_{n+1} = y_n + h f(x_n, y_n)$$

$$\text{se tiene } \Phi(x_n, y_n, h) = f(x_n, y_n)$$

entonces si f es lipschitz en y $\rightarrow \Phi$ lo es.

Método de Heun.

$$y_{n+1} = y_n + \frac{h}{2} [f(x_n, y_n) + f(x_n + h, y_n + h f(x_n, y_n))]$$

$\downarrow \Phi(x_n, y_n, h)$

$$\begin{aligned}
 |\Phi(x, y, h) - \Phi(x, \bar{y}, h)| &= \left| \frac{1}{2} (f(x, y) - f(x, \bar{y})) + \right. \\
 &\quad \left. \frac{1}{2} (f(x+h, y+h f(x, y)) - f(x+h, \bar{y}+h f(x, \bar{y}))) \right| \\
 &\leq \frac{1}{2} |f(x, y) - f(x, \bar{y})| + \frac{1}{2} |f(x+h, y+h f(x, y)) - f(x+h, \bar{y}+h f(x, \bar{y}))| \\
 &\leq \underbrace{\frac{1}{2} k |y - \bar{y}|}_{\text{es lipchitz.}} + \frac{1}{2} k |y + h f(x, y) - (\bar{y} + h f(x, \bar{y}))| \\
 &\leq \frac{1}{2} k |y - \bar{y}| + \frac{1}{2} k \left(|y - \bar{y}| + h |f(x, y) - f(x, \bar{y})| \right) \\
 &\leq k |y - \bar{y}| + \frac{1}{2} k h (k |y - \bar{y}|) = \underbrace{\left(k + \frac{k^2 h}{2} \right)}_{k^*} |y - \bar{y}|
 \end{aligned}$$

$\rightarrow \Phi$ es lipchitz.

MÉTODOS IMPLÍCITOS



1) EULER hacia atrás (Backward EULER)

$$y_{n+1} = y_n + h f(x_{n+1}, y_{n+1})$$

hacia atrás

EULER

hacia adelante.



Ejemplo: $y' = 2y$ $y(0) = 1$ $h = 0,1$

EULER hacia adelante:

$$\begin{aligned} y_1 &= y_0 + h(z y_0) = 1 + h(2 \cdot 1) = 1 + 0,1 \cdot 2 \\ &= 1 + 0,2 \\ &= 1,2 \end{aligned}$$

$$y_1 (\text{euler hacia adelante}) = 1,2$$

EULER hacia atrás $y_1 = y_0 + h(z y_1)$

$$y_1 = 1 + 0,1 \cdot 2(y_0)$$

$$y_1 = (1 + 0,2)y_0$$

$$(1 - 0,2)y_0 = 1 \quad y_1 = \frac{1}{0,8} = 1,25$$

Euler hacia atrás tiene error local $O(h^2)$

es un método de primer orden.

Método del Trapecio:

$$y_{n+1} = y_n + h \left(\frac{f(x_n, y_n) + f(x_{n+1}, y_{n+1})}{2} \right)$$

Error local es $O(h^3)$, es un método de segundo orden.

En estos métodos hay que, para hallar y_{n+1} , resolver en general una ecuación no lineal o un sistema de ecuaciones no lineales.

Podemos usar un Método de Newton-Raphson donde como valor inicial de y_{n+1} ($y_{n+1}^{(0)}$) se puede tomar el y_n .

Método Predictor-Corrector: (x ej para el método del trapecio)

Predigo con x ej EULER hacia adelante $y_{n+1}^{(P)} = y_n + h f(x_n, y_n)$
Corrijo con el método del trapecio

$$y_{n+1}^{(C)} = y_n + \frac{h}{2} (f(x_n, y_n) + f(x_{n+1}, y_{n+1}^{(P)}))$$

ESTABILIDAD

1) Euler hacia atrás

Problema test

$$y' = qy$$

$$y(0) = 1$$

$$y_{n+1} = y_n + h(qy_{n+1})$$


$$(1-hq)y_{n+1} = y_n$$

$$y_{n+1} = \frac{y_n}{1-hq} \quad y_0 = 1$$

$$y_n = \left(\frac{1}{1-hq}\right)^n$$

$$y_n \text{ estable si } \left| \frac{1}{1-hq} \right| < 1 \iff 1 < |z-1|$$

los z distan de $(1,0)$ mas que 1



16/10

Ejemplo:

$$y' = \underline{y^2 - zx} \quad y(0) = 1$$

Predicción: $y_{n+1}^{(P)} = y_n + h f(x_n, y_n)$
(EULER)

Corrección

(TRAPEZIO) $y_{n+1}^{(C)} = y_n + \frac{h}{2} (f(x_n, y_n) + f(x_{n+1}, y_{n+1}^{(P)}))$

Hallar valor aprox de $y(1)$ con $h = 0,1$

MNT.

$$y_1^{(P)} = y_0 + h \left(y_0 - \frac{2x_0}{y_0} \right) = 1 + 0,1 \left(1 - 2 \cdot \frac{0}{1} \right) = 1,1$$

$$y_1^{(C)} = y_0 + \frac{h}{2} \left(\left(y_0 - \frac{2x_0}{y_0} \right) + \left(y_1^{(P)} - \frac{2x_1}{y_1^{(P)}} \right) \right) =$$

$$1 + 0,05 \left(\left(1 - 2 \cdot \frac{0}{1} \right) + \left(1,1 - \frac{2 \cdot 0,1}{1,1} \right) \right) = 1,0959 = y_1$$

aprox de $y(0,1)$

$$y_2^{(P)} = y_1 + h \left(y_1 - \frac{2x_1}{y_1} \right) = 1,0959 + 0,1 \left(1,0959 - \frac{2 \cdot 0,1}{1,0959} \right) = 1,1873$$

$$y_2^{(C)} = y_1 + \frac{h}{2} \left(y_1 - \frac{2x_1}{y_1} + y_2^{(P)} - \frac{2x_2}{y_2^{(P)}} \right)$$

$$= 1,0959 + 0,05 \left(1,0959 - \frac{2 \cdot 0,1}{1,0959} + 1,1873 - \frac{2 \cdot 0,2}{1,1873} \right) = 1,1841$$

$$y_2 = 1,1841 \quad (\text{aprox de } y(0,2))$$

Repetimos hasta obtener y_{10} que sería una aproximación de $y(1)$

EN MATLAB:

- Ode23

- Ode45

Ejemplo:

$$\begin{cases} \dot{x} = -y & \rightarrow \ddot{x} = -\dot{y} = -x \\ \dot{y} = x & \rightarrow \ddot{y} = -x \\ x(0) = 1 & \left. \begin{array}{l} \ddot{x} + x = 0 \\ x(0) = 1 \end{array} \right. \\ y(0) = 0 & \dot{x}(0) = 0 \end{cases}$$

intervalo de la variable t.

$$y' = F(t, y)$$

$$[T, Y] = \text{ode23} ('F', TSPAN, Y0)$$

abscisas en las que fue evaluado. Valores de y en esas abscisas

$$\rightarrow x = \cos t$$


condición inicial (es 1 columna)

nombre del programa.m (function) donde calculamos $F(t, y)$ (el resultado debe ser una columna).


function $\dot{y} = \text{circ}(t, y)$ } archivo circ.m
 $y' = [-y(2) \ y(1)]$;

$[T, Y] = \text{ode23}('circ', [0 \ 2*pi], [1, 0]')$;


plot (T, Y(:, 1))



plot (T, Y(:, 2))



plot (Y(:, 1), Y(:, 2))



Región de estabilidad: método del trapecio

$$y_{n+1} = y_n + \frac{h}{2} (f(x_n, y_n) + f(x_{n+1}, y_{n+1}))$$

Problema test:

$$y' = qy$$

$$y(0) = 1$$

$$y_{n+1} = y_n + \frac{h}{2} (qy_n + qy_{n+1})$$


$$(1 - \frac{hq}{2}) y_{n+1} = (1 + \frac{hq}{2}) y_n \rightarrow y_{n+1} = \left[\frac{1 + \frac{hq}{2}}{1 - \frac{hq}{2}} \right] y_n$$

$$y_n = \left(\frac{1 + \frac{hq}{2}}{1 - \frac{hq}{2}} \right)^n$$

$$y_n \text{ acotado si } \left| \frac{1 + \frac{hq}{z}}{1 - \frac{hq}{z}} \right| < 1 \quad z = hq.$$

$$\rightarrow \frac{|z+z|}{|z-z|} < 1 \rightarrow |z-(-z)| < |z-z| \rightarrow \text{dist a } (z, 0) \\ \downarrow \text{dist a } (-z, 0)$$

$\Leftarrow \operatorname{Re}(z) < 0$.



Región de estabilidad : Método de HEUN .

$$y_{n+1} = y_n + \frac{h}{2} \left(f(x_n, y_n) + f(x_{n+1}, y_n + h f(x_n, y_n)) \right) \\ y_n + h q y_n$$

Problema test :


$$y' = qy \quad y_{n+1} = y_n + \frac{h}{2} \left(qy_n + q(y_n + hqy_n) \right) \\ y(0) = 1$$

$$y_{n+1} = y_n + hqy_n + \frac{h^2}{2} q^2 y_n$$

$$y_{n+1} = \left(1 + hq + \frac{(hq)^2}{2} \right) y_n$$

$$y_n = \left[1 + hq + \frac{(hq)^2}{2} \right]^n$$

Región de estabilidad :



$$\left| 1 + z + \frac{z^2}{2} \right| < 1 \rightarrow \left| z + 2z + z^2 \right| < 1 - \left| 1 + 2z + z^2 \right| < 2$$

La región de estabilidad de Euler está contenida en esta
 R. Euler: $|z+1| < 1$

$$\text{Si } |z+1| < 1 \rightarrow |(z+1)^2 + 1| \leq |(z+1)^2| + |1| = |z+1|^2 + 1 < 1^2 + 1 = 2$$


MINIMOS CUADRADOS:

Ejemplo: Ley de OHM: $V = RI$

Quiero determinar la resistencia de un componente eléctrico.

Puedo obtener varias mediciones

Cada medida me da una lectura simultánea de V y I .




Queremos determinar la recta por el origen que mejor "ajusta" a ese conjunto de puntos.

Dada una recta por el origen calculamos: $d_1^2 + d_2^2 + \dots + d_n^2 = F(\alpha)$

La solución de mínimos cuadrados es la que minimiza $F(\alpha)$

Ejemplo:



Quiero hallar la recta horizontal que mejor "ajusta" a esos 3 puntos.

1) Criterio de mínimos cuadrados.

$$\begin{aligned} y = \alpha \quad F(\alpha) &= d_1^2 + d_2^2 + d_3^2 = \alpha^2 + (1-\alpha)^2 + \alpha^2 \\ &= \alpha^2 + 1 - 2\alpha + \alpha^2 + \alpha^2 = 1 - 2\alpha + 3\alpha^2 \end{aligned}$$

$$\frac{dF}{d\alpha} = 2 + 6\alpha = 0 \rightarrow \alpha = \frac{1}{3}$$

2) Norma infinito.

$$F(x) = \max \{d_1, d_2, d_3\}$$

$$\min F(x) = \min \{\max \{d_i\}\}$$


$$x = 1/2$$

3) Norma 1. $\|x\|_1 = |x_1| + |x_2| + \dots + |x_n|$

$$F(x) = d_1 + d_2 + d_3$$

Recta que mejor ajusta a un conjunto de puntos.

Regressión lineal



Tengo m puntos P_1, P_2, \dots, P_m

$$P_i = (x_i, y_i) \quad i=1, 2, \dots, m$$

$$\sum_{i=1}^m$$

$$\min_{k, \beta} \left\{ \sum_{i=1}^m d_i^2 \right\}$$

$$F(k, \beta) = \sum_{i=1}^m d_i^2 = \sum_{i=1}^m (y_i - (kx_i + \beta))^2$$

$$= \sum_{i=1}^m [k^2 x_i^2 + 2k \beta x_i + \beta^2 + y_i^2 - 2y_i(kx_i + \beta)]$$

$$= \sum_i (k^2 x_i^2 + 2k \beta x_i + \beta^2 - 2kx_i y_i - 2\beta y_i + y_i^2)$$

$$= k^2 \left(\sum_i x_i^2 + 2k \beta \left(\sum_i x_i \right) + m \beta^2 - 2k \sum_i x_i y_i - 2\beta \sum_i y_i + \sum_i y_i^2 \right)$$

$$\min_{k, \beta} F(k, \beta)$$

$$k, \beta$$

$$\frac{\partial F}{\partial k} = 0 = 2k \left(\sum_i x_i^2 \right) + 2m \beta \left(\sum_i x_i \right) - 2 \sum_i x_i y_i$$


$$\frac{\partial F}{\partial \beta} = 0 = 2k \left(\sum_i x_i \right) + 2m \beta - 2 \sum_i y_i$$

$$\rightarrow \begin{bmatrix} \sum_i x_i^2 & \sum_i x_i \\ \sum_i x_i & m \end{bmatrix} = \begin{pmatrix} \alpha \\ \beta \end{pmatrix} = \begin{pmatrix} \sum_i x_i y_i \\ \sum_i y_i \end{pmatrix} \rightarrow \alpha, \beta \text{ óptimos.}$$

Se puede probar que esta recta pasa por el centro de gravedad de los puntos $(\bar{x}, \bar{y}) = \left(\frac{\sum x_i}{m}, \frac{\sum y_i}{m} \right)$ con pendiente $\alpha = \frac{\sum_i x_i y_i}{\sum_i x_i}$

$$\begin{cases} x'_i = x_i - \bar{x} \\ y'_i = y_i - \bar{y} \end{cases}$$

Ajuste con una parábola.



$$F(\alpha, \beta, \gamma) = \sum_{i=1}^{i=m} d_i^2 \quad d_i = |y_i - (\alpha x_i^2 + \beta x_i + \gamma)|$$

$$F(\alpha, \beta, \gamma) = \sum_i (y_i - (\alpha x_i^2 + \beta x_i + \gamma))^2$$

$$\left\{ \begin{array}{l} \frac{\partial F}{\partial \alpha} = 0 \\ \frac{\partial F}{\partial \beta} = 0 \\ \frac{\partial F}{\partial \gamma} = 0 \end{array} \right. \xrightarrow{\text{sistema lineal}} (\alpha, \beta, \gamma) \text{ óptimos.}$$

Tenemos:

- Un conjunto de m puntos (o mediciones) $P_i = (x_i, y_i) \ i=1, 2, \dots, m$
- Una familia de funciones:

En el modelo lineal esta familia es un espacio vectorial

de funciones de dimensión finita.

Sea $\{\varphi_1(x), \varphi_2(x), \dots, \varphi_n(x)\}$ una base de un espacio vectorial, una función genérica de ese espacio será $\psi(x) = \alpha_1\varphi_1(x) + \alpha_2\varphi_2(x) + \dots + \alpha_n\varphi_n(x)$

- Consideramos la función $F(\alpha_1, \alpha_2, \dots, \alpha_n) = \sum (y_i - \psi(x_i))^2$
 (suma de distancias verticales al cuadrado entre los P_i y el correspondiente punto en la ψ)

$$F(\alpha_1, \alpha_2, \dots, \alpha_n) = \begin{vmatrix} y_1 - (\alpha_1\varphi_1(x_1) + \alpha_2\varphi_2(x_1) + \dots + \alpha_n\varphi_n(x_1)) \\ y_2 - (\alpha_1\varphi_1(x_2) + \alpha_2\varphi_2(x_2) + \dots + \alpha_n\varphi_n(x_2)) \\ \vdots \\ y_m - (\alpha_1\varphi_1(x_m) + \alpha_2\varphi_2(x_m) + \dots + \alpha_n\varphi_n(x_m)) \end{vmatrix}^2$$

$$\text{Sea } y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}; A = \begin{bmatrix} \varphi_1(x_1) & \varphi_2(x_1) & \dots & \varphi_n(x_1) \\ \varphi_1(x_2) & \varphi_2(x_2) & \dots & \varphi_n(x_2) \\ \vdots & & & \\ \varphi_1(x_m) & \varphi_2(x_m) & \dots & \varphi_n(x_m) \end{bmatrix}; \alpha = \begin{pmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{pmatrix}$$

$$F(\alpha) = \|y - Ax\|_2^2$$

cambio de notación $y \rightarrow b$

$\alpha \rightarrow x$

$$F(x) = \|Ax - b\|_2^2$$

El problema de mínimos cuadrados lineal es min $F(x)$

$$\min_x \|Ax - b\|_2^2$$

ECUACIONES NORMALES:

Teorema: x minimiza $\|b - Ax\|_2 \iff b - Ax \in (\text{Im}(A))^\perp$
 $\iff A^t(b - Ax) = 0$.

Dem: (\Leftarrow) Sea $x / A^t(b - Ax) = 0$.

$$b - Ay = b - Ax + A(x - y)$$

$$\|b - Ay\|_2^2 = \|(b - Ax) + A(x - y)\|_2^2 = \|b - Ax\|_2^2 + \|A(x - y)\|_2^2 + 2[A(x - y)]^t (b - Ax) \quad (*)$$

$$[A(x - y)]^t (b - Ax) = ((x - y)^t A^t)(b - Ax) = (x - y)^t \underbrace{(A^t(b - Ax))}_{=0}$$

$$\rightarrow \|b - Ay\|_2^2 = \|b - Ax\|_2^2 + \|A(x - y)\|_2^2.$$

$$\rightarrow \|b - Ay\| \geq \|b - Ax\|_2 \rightarrow x \text{ minimiza } \|b - Ay\|_2$$

obs: igualdad si $A(x, y) = \vec{0}$

Supongamos que: $A^t(b - Ax) = z \neq \vec{0}$

Si $x - y = -\varepsilon z$ para $\varepsilon > 0$ suficientemente pequeño

$$(y = x + \varepsilon z)$$

(*) queda:

$$\|b - Ay\|_2^2 = \|b - Ax\|_2^2 + \varepsilon^2 \|Az\|_2^2 - 2\varepsilon \underbrace{(Az)^t (b - Ax)}_{z^t A^t (b - Ax)}$$

$$= \|b - Ax\|_2^2 + \varepsilon^2 \|Az\|_2^2 - 2\varepsilon \|z\|_2^2$$

$$< \|b - Ax\|_2^2$$

↑ si $\varepsilon < \varepsilon_0$

$$\rightarrow F(y) = F(x)$$

$\rightarrow x$ no minimiza

$$\frac{z^t z}{\|Az\|_2^2} = \varepsilon_0.$$

Ecuaciones normales: $A^t b - A^t Ax = 0$

$$\boxed{A^t Ax = A^t b} \quad A \text{ es mxn (en general m} > n)$$

$x \in \mathbb{R}^n$

$A^t b$ es $n \times 1$.

$b \in \mathbb{R}^m$

$A^t A$ es $n \times n$.

A^t es $n \times m$

Si $A^t A$ es invertible, resolviendo el sistema anterior de ecuaciones (ecuaciones normales) obtengo la solución del problema de mínimos cuadrados.

En Matlab $\min \|Ax - b\|_2$ lo resuelve con "\\" retrobarra
 $x = A \backslash b$.

28/10

Ejemplo:

$$A = \begin{bmatrix} 1 & 1 & 1 \\ \varepsilon & 0 & 0 \\ 0 & \varepsilon & 0 \\ 0 & 0 & \varepsilon \end{bmatrix} \quad b = \begin{pmatrix} 1 \\ 0 \\ 0 \\ 0 \end{pmatrix} \quad \varepsilon \ll 1, \quad Ax \approx b.$$

Ecuaciones Normales:

$$A^t A = \begin{bmatrix} 1+\varepsilon^2 & 1 & 1 \\ 1 & 1+\varepsilon^2 & 1 \\ 1 & 1 & 1+\varepsilon^2 \end{bmatrix} \quad A^t b = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

$$A^t A x = A^t b \quad \text{La solución exacta es } x = \frac{1}{3+\varepsilon^2} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

Si $\varepsilon > \varepsilon_m$ pero $\varepsilon^2 < \varepsilon_m$ entonces en la diagonal de $A^t A$ quedan 1 ($f_1(1+\varepsilon^2) = 1$)

Al calcular $A^t A$ y almacenarla me queda la matriz $\begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$ que no es invertible.

Me queda que el sistema que se resuelve tiene infinitas soluciones (en vez de una solución única)

Las ecuaciones normales pueden ser un método numéricamente malo porque $\text{cond}_2(A^t A)$ sea demasiado grande.

Vamos a ver otros métodos para resolver el problema de mínimos cuadrados: $\min \|Ax - b\|_2$.

x

Veremos - descomposición QR

- " SVD

DESCOMPOSICIÓN QR:

- ¿Qué es?
- ¿Cómo se usa en mínimos cuadrados?
- Métodos para hallar la descomposición QR.

Teorema: a) Sea A matriz real $m \times n$ $m \geq n$

→ ∃ Q matriz ortogonal $m \times m$ y R matriz $m \times n$ triangular superior tales que $A = Q.R$ (forma completa)

b) ∃ \bar{Q} matriz $m \times n$ tal que $\bar{Q}^t Q = I_{n,n}$ y \bar{R} es una matriz $n \times n$ triangular superior tales que $A = \bar{Q}\bar{R}$ (forma compacta o económica)

$$Q^t Q = I_{n,n}$$

$$R = \begin{bmatrix} * & * & * \\ * & * & * \\ \vdots & \vdots & \vdots \\ 0 & 0 & 0 \end{bmatrix}$$

$$Q \cdot R = \begin{bmatrix} * & * & * \\ * & * & * \\ \vdots & \vdots & \vdots \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} * & * & * \\ 0 & * & * \\ \vdots & \vdots & \vdots \\ 0 & 0 & * \end{bmatrix} = A$$

$m \times m$ $m \times n$

MNT

$$\bar{\Phi} = \begin{bmatrix} & \\ & \end{bmatrix} \quad \text{Matriz } mxn. \quad \left\{ \bar{\Phi}^{(1)}, \bar{\Phi}^{(2)}, \dots, \bar{\Phi}^{(n)} \right\}$$

Columnas orthonormadas de \mathbb{R}^m

$$\bar{\Phi}^t \cdot \bar{\Phi} = \begin{bmatrix} & & \\ & & \end{bmatrix} \begin{bmatrix} & \\ & \end{bmatrix} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ 0 & 0 & \dots & 1 \end{bmatrix} = I_{nxn}$$

$$\bar{R} = \begin{bmatrix} & & \\ & & \\ & & \\ & & \\ 0 & & \end{bmatrix} \quad \text{Matriz } nxn.$$

$$\bar{\Phi} \cdot \bar{R} = A \quad mxn * nxn = nxn$$

Supongamos tenemos la descomposición QR de A.

$$\min_x \|Ax - b\|_2$$

$$Q \text{ ortogonal: } \|Qy\|_2 = \|y\|_2$$

además Q^t es también ortogonal

$$\|Ax - b\|_2 = \|Q^t(Ax - b)\|_2 = \|Q^t \cdot Q \cdot R x - b\|_2 = \|Rx - Q^t b\|_2$$

$$\min_x \|Ax - b\|_2 = \min_x \|Rx - \underbrace{Q^t b}_{{b'}\|_2}\|_2$$

$$\begin{aligned} \|Rx - b'\|_2^2 &= (R_{11}x_1 + R_{12}x_2 + \dots + R_{1n}x_n - b'_1)^2 + \\ &\quad (R_{21}x_1 + R_{22}x_2 + \dots + R_{2n}x_n - b'_2)^2 + \dots + \\ &\quad (R_{n1}x_1 + R_{n2}x_2 + \dots + R_{nn}x_n - b'_n)^2 + b'_{n+1}^2 + b'_{n+2}^2 + \dots + b'_{m+1}^2 \end{aligned}$$

El x que minimiza lo anterior cumple:

$$R_{11}x_1 + R_{12}x_2 + \dots + R_{1n}x_n = b'_1$$

⋮

$$R_{nn}x_n$$

El valor mínimo es $\sqrt{b'_{n+1}^2 + \dots + b'_{m+1}^2}$

x complejo: $\bar{R}x = \bar{b}'$ \bar{b}' son las n primeras posiciones de $Q^t b$

$$Q^t b = \begin{bmatrix} Q^{(1)t} \\ Q^{(2)t} \\ \vdots \\ Q^{(n)t} \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} = b' = \begin{pmatrix} Q^{(1)t} \cdot b \\ Q^{(2)t} \cdot b \\ \vdots \\ Q^{(n)t} \cdot b \end{pmatrix}$$

$$\bar{b}' = \bar{Q}^t \cdot b \quad 1) \min_{\bar{x}} \|A\bar{x} - b'\|_2$$

2) Halla la descomposición económica $\bar{Q}\bar{R}$ de A .

3) x es solución de $\bar{R}\bar{x} = \bar{Q}^t b$

(sistema $n \times n$, indeterminado si algún $r_{jj} = 0$)

4) Si quiero calcular el valor del mínimo con x_0 solución de 3. Calculo $\|Ax_0 - b\|_2$.

Métodos para hallar la descomposición QR.

1) Gram-Schmidt

2) Simetría de Householder.

3) Rotaciones de Givens.

Supondremos que A es de rango n

Veamos como hallar las primeras n columnas de Q .

Paso 1 Definimos $= \frac{1}{\|A^{(1)}\|_2} \cdot A^{(1)}$ $R_{11} = \|A^{(1)}\|_2$
 $(A^{(1)} = R_{11} Q^{(1)})$

Paso k: Disponiendo del conjunto orthonormal

$$\text{que cumple: } [\phi^{(1)}, \dots, \phi^{(j)}] = [A^{(1)}, \dots, A^{(j)}] \quad j=1, 2, \dots, k-1$$

1º buscamos $\tilde{\phi}^{(k)} = A^{(k)} - \sum_{i=1}^{k-1} c_i \phi^{(i)}$ que verifique:

$$\tilde{\phi}^{(k)} \perp \phi^{(1)}$$

$$\tilde{\phi}^{(k)} \perp \phi^{(2)}$$

:

$$\tilde{\phi}^{(k)} \perp \phi^{(k-1)}$$

$$\tilde{\phi}^{(k)} \times \phi^{(1)} = 0$$

$$\tilde{\phi}^{(k)} \times \phi^{(2)} = 0$$

$$\tilde{\phi}^{(k)} \times \phi^{(k-1)} = 0$$

$$\Rightarrow A^{(k)T} \phi^{(1)} - c_1 \underbrace{\phi^{(1)T} \phi^{(1)}}_{=1} = 0 \rightarrow c_1 = A^{(k)T} \phi^{(1)}$$

$$c_i = A^{(k)T} \phi^{(i)}$$

$$\rightarrow \tilde{\phi}^{(k)} = A^{(k)} - \sum_{i=1}^{k-1} (A^{(k)T} \phi^{(i)}) \phi^{(i)}$$

$$\phi^{(k)} = \frac{\tilde{\phi}^{(k)}}{\|\tilde{\phi}^{(k)}\|_2}$$

$$(\|\tilde{\phi}^{(k)}\|_2 \phi^{(k)} = \tilde{\phi}^{(k)} = A^{(k)} - \sum_{i=1}^{k-1} (A^{(k)T} \phi^{(i)}) \phi^{(i)}$$

$$\rightarrow A^{(k)} = \sum_{i=1}^{k-1} (A^{(k)T} \phi^{(i)}) \phi^{(i)} + \|\tilde{\phi}^{(k)}\|_2 \phi^{(k)}$$

$$\rightarrow R_{1k} = A^{(k)T} \phi^{(1)}, R_{2k} = A^{(k)T} \phi^{(2)}, \dots, R_{k-1k} = A^{(k)T} \phi^{(k-1)}$$

$$R_{kk} = \|\tilde{\phi}^{(k)}\|_2$$

SVD (Descomposición en valores singulares)

Teorema: Sea A matriz $m \times n$ de rango r

$\rightarrow \exists$ una matriz $\Sigma_{m \times n}$, $U_{m \times m}$, $V_{n \times n}$

tales que: $\Sigma = \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \\ & 0 & & \\ & & & 0 \end{bmatrix}$

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$$

(σ_i son los valores singulares de A)

U es ortogonal, V es ortogonal

tales que: $A = U\Sigma V^t$ (Forma Completa)

$$(m \times n) = (m \times m) \times (m \times n) \times (n \times n)$$

Forma compacta (o económica):

$$U = \begin{bmatrix} & \\ U_1 & U_2 \end{bmatrix} \quad U_1 \text{ es matriz } m \times r$$

$$V = \begin{bmatrix} V_1 & V_2 \end{bmatrix} \quad V_1 \text{ es matriz } n \times r$$

$$\Sigma_1 = \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \end{bmatrix}$$

matriz $r \times r$. entonces $A = U_1 \Sigma_1 V_1^t$
 $(m, n) = (m \times r) \times (r \times r) \times (r \times n)$

Aplicación al problema de mínimos cuadrados

$$\min_x \|b - Ax\|_2$$

x

$$A = U\Sigma V^t$$

$$\text{Definimos } y = V^t x = \begin{bmatrix} V_1^t \\ \vdots \\ V_r^t \end{bmatrix} = \begin{bmatrix} y_1 \\ \vdots \\ y_r \end{bmatrix}$$

$$\|b - Ax\|_2^2 = \|UU^t b - U\Sigma V^t x\|_2^2 = \|U(U^t b - \Sigma y)\|_2^2 =$$

$$\|U^t b - \Sigma y\|_2^2 = \left\| \begin{bmatrix} U_1^t b \\ \vdots \\ U_r^t b \end{bmatrix} - \begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & & \\ \vdots & & \ddots & \\ 0 & 0 & \dots & 0 \end{bmatrix} \begin{bmatrix} y_1 \\ \vdots \\ y_r \end{bmatrix} \right\|_2^2 =$$

$$= \left\| \begin{bmatrix} U_1^t b - \sum_1 y_1 \\ U_2^t b \end{bmatrix} \right\|_2^2 = \|U_1^t b - \sum_1 y_1\|_2^2 + \|U_2^t b\|_2^2$$

La expresión anterior se minimiza si $\sum_1 y_1 = U_1^t b$,
o sea $y_1 = \sum_1^{-1} U_1^t b$ con $\sum_1^{-1} = \begin{bmatrix} 1/\sigma_1 & & \\ & \ddots & \\ & & 1/\sigma_r \end{bmatrix}$

Solución en y es $y = \begin{bmatrix} \sum_1^{-1} U_1^t b \\ y_2 \end{bmatrix}$ y_2 cualquiera, $y = V^t x$


$$\Rightarrow x = Vy = \begin{bmatrix} v_1 & v_2 \end{bmatrix} \begin{bmatrix} \sum_1^{-1} U_1^t b \\ y_2 \end{bmatrix} \rightarrow x = Vy$$

$$= \begin{bmatrix} v_1 & v_2 \end{bmatrix} \cdot \left(\begin{bmatrix} \sum_1^{-1} U_1^t b \\ 0 \end{bmatrix} + \begin{bmatrix} 0 \\ y_2 \end{bmatrix} \right)$$

$$= v_1 \sum_1^{-1} U_1^t b + v_2 y_2, \quad y_2 \in \mathbb{R}^{n-r} \text{ arbitrario}$$

La sol es de la forma $x_0 + \ker(A)$


Solución de norma mínima



Prop: De todos los vectores del conjunto $\vec{x}_0 + \ker(A)$

\vec{x}_0 es el que tiene norma 2 más chica (el más cercano al origen)

$$\|\vec{x}_0\|_2 \leq \|\vec{x}_0 + v_2 y_2\|_2 \quad \forall y_2 \in \mathbb{R}^{n-r}$$



Hay que probar que $\vec{x}_0 \perp v_2 y_2$.

$$(v_2 y_2)^t \cdot \vec{x}_0 = (v_2^t v_2^t) (\vec{x}_0 \cdot v_2^t) = y_2^t (\vec{x}_0 \cdot v_2^t) = 0$$

PSEUDOINVERSA:

Def: Se llama matriz pseudoinversa de A a la matriz
 $A^+ = V_1 \Sigma_1^{-1} U_1^t = V \Sigma^+ U^t$, donde Σ^+ se obtiene
 traspmando Σ y poniendo $\frac{1}{\sigma_i}$ en las posiciones
 de los σ_i

$$\Sigma^+ = \begin{bmatrix} \frac{1}{\sigma_1} & & & \\ & \ddots & & 0 \\ & & \frac{1}{\sigma_r} & \\ 0 & & & \ddots \end{bmatrix}$$

Obs: 1) Si A es $n \times n$ invertible $\rightarrow A^+ = A^{-1}$

2) A es $m \times n$ $m \geq n$ $\text{rango}(A) = n$.

$$\text{E.N. } A^t A x = A^t b \rightarrow x = (A^t A)^{-1} A^t b$$

$$\text{En este caso se tiene que } A^+ = (A^t A)^{-1} A^t$$

Es una inversa de A a la izquierda: $[(A^t A)^{-1} A^t] A = (A^t A)^{-1} (A^t A) = I_{n \times n}$

MATLAB: $Ax \approx b$.

$x = A \setminus b$ da la solución del problema de mínimos cuadrados usando descomposición QR de A . Si estamos en el caso de infinitas soluciones elige una de ese conjunto con cierto criterio (es solución tipo básico: tiene varias posiciones en 0)


Otra forma: $\text{pinv}(A)$ me da la pseudoinversa de A
 $x = \text{pinv}(A) b$

Esta solución es la de norma mínima.

Método de Householder para hallar la descomp QR de A:

Simetría respecto a un hiperplano por el origen:

(subespacio vectorial con 1 dimensión menos que el espacio)



$$H(x) = x - (z u u^t) x \quad \|u\|_2 = 1$$


Si $y \in$ Hiperplano: $y \perp u$

$$H(y) = y - (z u u^t) y = y - z u (\underbrace{u^t y}_0) = y.$$

$$H(u) = u - (z u u^t) u = u - z u (\underbrace{u^t u}_1) = u - z u = -u.$$

H es ortogonal

$$H = \text{Id} - z u u^t$$



H que convierte a x en $(\|x\|_2, 0)$ es tal que su vector u cumple:

$$u = \frac{x - x'}{\|x - x'\|_2}$$

$$A = \begin{bmatrix} & & & \\ A^{(1)} & A^{(2)} & \dots & A^{(n)} \\ & & & \end{bmatrix}$$

$$\text{Hallar } H_1 / H_1 A^{(1)} = \begin{pmatrix} \|A^{(1)}\|_2 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

$$H_1 \cdot A = \begin{bmatrix} \|A^{(1)}\|_2 & & & \\ 0 & A^{(2)} & \dots & A^{(n)} \\ 0 & & & \end{bmatrix}$$

A'

$$\text{Constuyo } H_2 / H_2 \cdot A^{(2)} = \begin{pmatrix} \|A^{(2)}\|_2 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

$$H_2 \cdot H_1 \cdot A = \begin{bmatrix} \|A^{(1)}\| & \times \\ 0 & \|A^{(2)}\| \\ 0 & 0 \\ \vdots & \vdots \\ 0 & 0 \end{bmatrix} \quad \boxed{\quad}$$

4/11

MÍNIMOS CUADRADOS NO LINEAL.

Hasta ahora nuestro modelo era lineal (en los parámetros). Tenemos un conjunto de m puntos (t_i, y_i) $i = 1, 2, \dots, m$ y hallabamos una función $\hat{y}(t) = x_1 \varphi_1(t) + x_2 \varphi_2(t) + \dots + x_n \varphi_n(t)$ que mejor ajusta al conjunto de puntos en el sentido de mínimos cuadrados.

O sea resolvíramos: $\min \| \underbrace{Y - AX}_r \|_2^2$ $Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$

X residuo.

 $A = \begin{bmatrix} \varphi_1(t_1) & \varphi_2(t_1) & \dots & \varphi_n(t_1) \\ \vdots & \vdots & & \vdots \\ \varphi_1(t_m) & \varphi_2(t_m) & \dots & \varphi_n(t_m) \end{bmatrix}$
 $r(x) = Y - AX.$

Simbólicamente $AX \approx Y$
(sistema sobre-determinado)

Caso no lineal: La función de ajuste no es lineal en los parámetros (las x_i)

$f(x, t)$ es la función de ajuste (es una familia de funciones que depende de n parámetros)

Ejemplo: $f(x, t) = \frac{x_1 \sin(t+x_2)}{1+x_3 t^2}$

El problema que queremos resolver es:

$$\min \| r(x) \|_2^2$$

x

MNT.

$$r(x) = \begin{pmatrix} y_1 - f(x, t_1) \\ y_2 - f(x, t_2) \\ \vdots \\ y_m - f(x, t_m) \end{pmatrix}$$

lo podemos ver como un sistema no lineal sobredeterminado

$$r(x) \approx 0$$

Newton-Raphson: $r(x) = 0 \quad r: \mathbb{R}^n \rightarrow \mathbb{R}^m$

en la instancia k :

$$\begin{aligned} Jr(x^{(k)}) (x^{(k+1)} - x^{(k)}) &= -r(x^{(k)}) \\ \rightarrow x^{(k+1)} &= x^{(k)} - [J_n(x^{(k)})]^{-1} r(x^{(k)}) \end{aligned}$$

Método de Gauss-Newton:

$$r(x) \approx \vec{0} \quad r: \mathbb{R}^n \rightarrow \mathbb{R}^m$$

En la instancia k : 1) linearizamos el sistema (sobredet) alrededor de $x^{(k)}$

$$r(x) = r(x^{(k)}) + Jr(x^{(k)}) (x - x^{(k)}) + \text{términos de } 2^{\text{do}} \text{ orden}$$

Jr es una matriz $m \times n$

$$(Jr)_{i,j} = \frac{\partial r_i(x)}{\partial x_j}$$

En vez de minimizar $r(x)$ vamos a minimizar la expresión linearizada alrededor de $x^{(k)}$

$$\tilde{r}^{(k)}(x) = r(x^{(k)}) + Jr(x^{(k)}) (x - x^{(k)})$$

$$\text{Resolvemos: } \min_x \|\tilde{r}^{(k)}(x)\|_2^2 = \min_x \|Jr(x^{(k)}) (x - x^{(k)}) + r(x^{(k)})\|_2^2$$

Es un problema de MC lineal: aplicamos ecuaciones normales, QR o SVD.

$$\begin{aligned} Jr(x^{(k)}) (x - x^{(k)}) + r^{(k)} &\approx 0 \\ \rightarrow Jr(x^{(k)}) \underbrace{(x - x^{(k)})}_{s^{(k)}} &\approx -r^{(k)} \end{aligned}$$

Algoritmo Gauss-Newton

1) Resuelvo el problema de M^c lineal $Jr(x^{(k)}) s^{(k)} \approx -r^{(k)}$

$$2) x^{(k+1)} = x^{(k)} + s^{(k)}$$

Criterios de parada: $\|x^{(k+1)} - x^{(k)}\| < tol$ o bien
 $\|r(x^{(k)})\|$ ya no cambia mucho

Ejemplo:

$$f(t, x) = x_1 e^{tx_2}$$

$$\begin{array}{c|cccc} t & 0,0 & 0,1 & 0,2 & 0,3 \\ \hline r & 2,0 & 0,7 & 0,3 & 0,1 \end{array}$$

$$r(x) = \begin{pmatrix} 2 & -x_1 e^0 \\ 0,7 & -x_1 e^{x_2} \\ 0,3 & -x_1 \cdot e^{2x_2} \\ 0,1 & -x_1 e^{3x_2} \end{pmatrix}$$

$$x^{(0)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$$

$$r(x^{(0)}) = \begin{pmatrix} 2-1 \\ 0,7-1 \\ 0,3-1 \\ 0,1-1 \end{pmatrix}$$

$$-r(x^{(0)}) = \begin{pmatrix} -1 \\ 0,3 \\ 0,7 \\ 0,9 \end{pmatrix}$$

$Jr(x)$ La construye por columnas

1º columna: Derivada parcial de r respecto a $x_1 =$

$$\begin{pmatrix} -1 \\ -e^{x_2} \\ -e^{2x_2} \\ -e^{3x_2} \end{pmatrix}$$

2º columna: Derivada parcial de r con respecto a x_2

$$\begin{pmatrix} 0 \\ -x_1 e^{x_2} \\ -2x_1 e^{2x_2} \\ -3x_1 e^{3x_2} \end{pmatrix}$$

$$Jr(x^{(0)}) = \begin{bmatrix} -1 & 0 \\ -1 & -1 \\ -1 & -2 \\ -1 & -3 \end{bmatrix}$$

$$Jr(x^{(0)}) s^{(0)} = \begin{pmatrix} -1 \\ 0,3 \\ 0,7 \\ 0,9 \end{pmatrix} \rightarrow s^{(0)} = \begin{pmatrix} 0,69 \\ -0,61 \end{pmatrix}$$

$$\rightarrow x^{(1)} = x^{(0)} + s^{(0)} = \begin{pmatrix} 1,69 \\ -0,61 \end{pmatrix}$$

$$x^{(k)} \quad \| r^{(k)} \|_2^2$$

1	0	2,39	$k=0$
1,69	-0,61	0,212	$k=1$
1,995	-0,93	0,007	$k=2$
1,994	-1,004	0,002	$k=3$
1,995	-1,009	0,002	$k=4$
1,995	-1,010	0,002	$k=5$

INTERPOLACIÓN

I) Interpolación polinómica

Tenemos $n+1$ puntos: $(x_0, y_0), (x_1, y_1), \dots, (x_n, y_n)$
 queremos hallar el polinomio de grado n que pasa por todos esos puntos. Se llama polinomio interpolador de grado n .

Teorema: Si las x_i son todas distintas entonces el polinomio interpolador de grado n existe y es único

Veremos 3 métodos para hallarlo:

1) Expresión con monomios

2) " de Lagrange

3) " " Newton

Expresión con monomios:

$$P_n(x) = a_0 + a_1 x + a_2 x^2 + \dots + a_n x^n$$

Tenemos $n+1$ incógnitas: a_0, a_1, \dots, a_n .

Impondremos que el polinomio pase por los puntos (x_i, y_i)

$$i=0, \dots, n.$$

$$P_n(x_0) = y_0 \quad P_n(x_1) = y_1 \quad \dots \quad P_n(x_k) = y_k \quad \dots \quad P_n(x_n) = y_n$$

queda:

$$a_0 + a_1 x_0 + a_2 x_0^2 + \dots + a_{n-1} x_0^{n-1} + a_n x_0^n = y_0.$$

$$a_0 + a_1 x_1 + a_2 x_1^2 + \dots + a_{n-1} x_1^{n-1} + a_n x_1^n = y_1.$$

⋮

$$a_0 + a_1 x_k + a_2 x_k^2 + \dots + a_{n-1} x_k^{n-1} + a_n x_k^n = y_k.$$

⋮

$$a_0 + a_1 x_n + a_2 x_n^2 + \dots + a_{n-1} x_n^{n-1} + a_n x_n^n = y_n$$

$$\rightarrow \left[\begin{array}{cccc|c} 1 & x_0 & x_0^2 & \dots & a_0 \\ 1 & x_1 & x_1^2 & & a_1 \\ \vdots & & & & \vdots \\ 1 & x_k & x_k^2 & \dots & a_{n-1} \\ \vdots & & & & \vdots \\ 1 & x_n & x_n^2 & \dots & a_n \end{array} \right] = \left[\begin{array}{c} y_0 \\ y_1 \\ \vdots \\ y_k \\ \vdots \\ y_n \end{array} \right]$$

Resolviendo este sistema cuadrado invertible tengo los coeficientes del polinomio.

matriz de Vandermonde

$$\text{prop: } \det(\text{Vander}) = \prod_{i < j} (x_j - x_i)$$

$$\begin{vmatrix} 1 & x_0 \\ 1 & x_1 \end{vmatrix} = x_1 - x_0$$

$$\begin{vmatrix} 1 & x_0 & x_0^2 \\ 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \end{vmatrix} = (x_1 - x_0)(x_2 - x_0)(x_2 - x_1)$$

6/11.

Interpolación de Lagrange.

En vez de usar las funciones $\{1, x, x^2, \dots, x^m\}$

Si tenemos los puntos $(x_0, y_0), (x_1, y_1), \dots, (x_m, y_m)$ vamos a considerar la fila $^{m \times 1}$ de polinomios (de grado m)

$$\{L_0, L_1, \dots, L_m\}$$

L_k cumple: $L_k(x_0) = 0$.

:

$$L_k(x_{k-1}) = 0$$

$$L_k(x_k) = 1$$

$$L_k(x_{k+1}) = 0$$

:

$$L_k(x_m) = 0$$

$$L_k(x) = k(x - x_0)(x - x_1) \dots (x - x_{k-1})(x - x_{k+1}) \dots (x - x_m)$$

$$1 = L_k(x_k) = k(x_k - x_0)(x_k - x_1) \dots (x_k - x_{k-1})(x_k - x_{k+1}) \dots (x_k - x_m)$$

$$\Rightarrow L_k(x) = \prod_{\substack{i=0 \\ i \neq k}}^{i=m} (x - x_i)$$

$$\frac{\prod_{\substack{i=0 \\ i \neq k}}^{i=m} (x_k - x_i)}{(x_k - x_k)}$$

$\{L_0, \dots, L_m\}$ son LI, son una base de P_m (polinomio de grado $\leq m$).

Si P_m es el polinomio interpolador de grado m de los datos $(x_i, y_i) \quad i = 0, \dots, m$

$$P_m(x) = \beta_0 L_0(x) + \beta_1 L_1(x) + \dots + \beta_m L_m(x)$$

$$y_m = P_m(x_k) = \underbrace{\beta_0 L_0(x_k)}_0 + \underbrace{\beta_1 L_1(x_k)}_0 + \dots + \underbrace{\beta_k L_k(x_k)}_{=1} + \dots + \underbrace{\beta_m L_m(x_k)}_0$$

$$\rightarrow \beta_k = y_k$$

$$\rightarrow P_m(x) = \sum_{i=0}^{i=m} y_i L_i(x)$$

Ejemplo:	x	1,1	1,2	1,4
	y	0,3	0,2	0,15

Determinemos el valor aproximado de $y(1,3)$

$$L_0(x) = \frac{(x-1,2)(x-1,4)}{(1,1-1,2)(1,1-1,4)} = \frac{(x-1,2)(x-1,4)}{(-0,1)(-0,3)}$$

$$L_1(x) = \frac{(x-1,1)(x-1,4)}{(1,2-1,1)(1,2-1,4)} = \frac{(x-1,1)(x-1,4)}{(0,1)(-0,2)}$$

$$L_2(x) = \frac{(x-1,1)(x-1,2)}{(1,4-1,1)(1,4-1,2)} = \frac{(x-1,1)(x-1,2)}{(0,3)(-0,2)}$$

$$P_2(x) = 0,3 L_0(x) + 0,2 L_1(x) + 0,15 L_2(x)$$

$$y(1,3) - P_2(1,3) = 0,3 \underbrace{L_0(1,3)}_{0,1(-0,1)} + 0,2 \underbrace{L_1(1,3)}_{0,2(-0,1)} + 0,15 \underbrace{L_2(1,3)}_{(0,2)(0,1)} \\ 0,03 \quad 0,03 \quad 0,06$$

Forma de Newton

Usamos la base $\left\{ \prod_{i=0}^{i=k} (x-x_i), \prod_{i=1}^{i=n-1} (x-x_0)(x-x_1), \prod_{i=2}^{i=n-1} (x-x_0)(x-x_1)(x-x_2), \dots, \prod_{i=0}^{i=n-1} (x-x_0), \dots, \prod_{i=0}^{i=n-1} (x-x_i) \right\}$

(ver LI)

$$P_m(x) = x_0 \cdot 1 + x_1(x-x_0) + x_2(x-x_0)(x-x_1) + \dots + x_m(x-x_0) \\ (x-x_1) \dots x(x-x^{m-1})$$

MNT.

$$y_0 = P_n(x_0) = x_0$$

$$y_1 = P_n(x_1) = x_0 + \alpha_1(x_1 - x_0)$$

$$y_2 = P_n(x_2) = x_0 + \alpha_1(x_2 - x_0) + \alpha_2(x_2 - x_1)(x_2 - x_1)$$

:

$$y_k = P_n(x_k) = x_0 + \alpha_1(x_k - x_0) + \dots + \alpha_k(x_k - x_0)(x_k - x_1)\dots(x_k - x_{k-1})$$

:

$$y_m = P_n(x_m) = x_0 + \alpha_1(x_m - x_0) + \dots + \alpha_m(x_m - x_0)(x_m - x_1)\dots(x_m - x_{m-1})$$


Queda:

$$\begin{bmatrix} 1 & & & & \\ & 1 & & & \\ & & 1 & & \\ & & & 1 & \\ & & & & 1 \end{bmatrix} \begin{pmatrix} x_0 \\ x_1 \\ \vdots \\ x_m \end{pmatrix} = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_m \end{pmatrix}$$

Resuelvo el sistema Δ en los x y luego:

$$P_m(x) = \sum_{i=0}^{m-1} \alpha_i \prod_{0 \leq k \leq i} (x - x_k)$$

Esquema de diferencias divididas:



de primer orden

$$f[x_i, x_{i+1}] = \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i}$$

$$f[x_{i-1}, x_i, x_{i+1}] = \frac{f[x_i, x_{i+1}] - f[x_{i-1}, x_i]}{x_{i+1} - x_{i-1}}$$

diferencias de segundo orden

diferencias de tercer orden.

$$f[x_{i-1}, x_i, x_{i+1}, x_{i+2}] = \frac{f[x_i, x_{i+1}, x_{i+2}] - f[x_{i-1}, x_i, x_{i+1}]}{x_{i+2} - x_{i-1}}$$

diferencias de cuarto orden

$$f[x_0, x_1, x_2, x_3, x_4] = \frac{f[x_1, x_2, x_3, x_4] - f[x_0, x_1, x_2, x_3]}{x_4 - x_0}$$

$$\text{En general: } f[x_0, x_1, \dots, x_n] = \frac{f[x_1, \dots, x_n] - f[x_0, \dots, x_{n-1}]}{x_n - x_0}$$

Ejemplo:

x	y	diff 1º ord.	diff 2º ord.	diff 3º ord.
2,0	1,3863			
2,3	1,9157	1,76467		
2,5	2,2907	1,87500	0,22067	
2,6	2,4843	1,93600	0,20333	-0,02889

$$P_3(x) = 1,3863 + 1,76467(x-2,0) + 0,22067(x-2,0)(x-2,3) \\ - 0,02889(x-2,0)(x-2,3)(x-2,5)$$

Estimar el valor de la función en $x=2,4$.

opción 1) $f(2,4) \approx P_3(2,4) = 2,1011$

opción 2) $P_2(x) = 1,9157 + 1,875(x-2,3) + 0,20333(x-2,3)(x-2,5)$
 $f(2,4) \approx P_2(2,4) = 2,1012$

Error en la interpolación polinómica.



Supongamos que los puntos (x_i, y_i) $i=0, \dots, n$ están en el gráfico de una función $y = f(x)$

Teorema: Error de interpolación:

$$= f(x) - P_n(x) = \frac{f^{(n+1)}(c)}{(n+1)!} (x-x_0)(x-x_1) \dots (x-x_n) \text{ donde } c \in [x_0, x_n]$$

Fenómeno de Runge

$$f(x) = \frac{1}{1+25x^2} \quad -1 \leq x \leq 1$$



Si tomamos n puntos equiespaciados y hacemos que n crezca se tiene que:

$$\max_{-1 \leq x \leq 1} |f(x) - P_n(x)| \xrightarrow{n} +\infty$$

11 / 11

Ejemplo:

$$f(x) = \sqrt{x}$$

x	1/4	4/9	1
y	1/2	2/3	1

Estimar $\frac{1}{\sqrt{2}}$ y dar una idea del error.

Teorema: (error del polinomio interpolador)

$$f(x) - P_n(x) = \frac{f^{(n+1)}(c)}{(n+1)!} (x-x_0)(x-x_1)\dots(x-x_n)$$

P_n es el polinomio interpolador por $(x_i, f(x_i))$ $i=0,\dots,n$

$$\begin{aligned} P_2(x) &= \underset{\text{Lagrange}}{\uparrow} \frac{1}{2} L_0(x) + \frac{2}{3} L_1(x) + 1 L_2(x) = \frac{1}{2} \frac{(x-4/9)(x-1)}{(1/4-4/9)(4/9-1)} \\ &\quad + \frac{2}{3} \frac{(x-1/4)(x-1)}{(4/9-1/4)(4/9-1)} + 1 \frac{(x-1/4)(x-4/9)}{(1-1/4)(1-4/9)} \end{aligned}$$

$$P_2(x) = \frac{72}{21} (x-4/9)(x-1) - \frac{216}{35} (x-1/4)(x-1) + \frac{36}{15} (x-1/4)(x-4/9)$$

$$\begin{aligned} \frac{1}{\sqrt{2}} &= \sqrt{\frac{1}{2}} \approx P_2(\frac{1}{2}) = \frac{72}{21} \left(\frac{1}{2}-\frac{4}{9}\right)\left(-\frac{1}{2}\right) - \frac{216}{35} \left(\frac{1}{4}\right)\left(-\frac{1}{2}\right) + \\ &\quad \frac{36}{15} \left(\frac{1}{4}\right)\left(\frac{1}{2}-\frac{4}{9}\right) \\ &= -\frac{2}{21} + \frac{27}{35} + \frac{1}{30} = \frac{-20 + 162 + 7}{210} = \frac{149}{210} = 0,7095238 \end{aligned}$$

$$\text{Error cometido: } \sqrt{\frac{1}{2}} - \frac{149}{210} = -2,417 \cdot 10^{-3}$$

$$\text{Error} = \frac{f^{(3)}(c)}{3!} (x-1/4)(x-4/9)(x-1) \quad x=\frac{1}{2}$$

$$= \frac{f^{(3)}(c)}{6} \underbrace{\left(\frac{1}{2}-\frac{1}{4}\right)\left(\frac{1}{2}-\frac{4}{9}\right)\left(\frac{1}{2}-1\right)}_{\frac{1}{18} \cdot \frac{1}{18} \cdot \frac{1}{2}} = -\frac{f^{(3)}(c)}{864} \quad c \in [1/4, 1]$$

$$f(x) = \sqrt{x} = x^{1/2}$$

$$f'(x) = \frac{1}{2} x^{-1/2}$$

$$f''(x) = \frac{1}{2} \left(-\frac{1}{2}\right) x^{-3/2}$$

$$f^{(3)}(x) = \frac{1}{2} \left(-\frac{1}{2}\right) \left(-\frac{3}{2}\right) x^{-5/2} = \frac{3}{8} x^{-5/2}$$

MNT

$$\text{Error} = -\frac{3/8 c^{-5/2}}{864} = \frac{1}{2304} c^{-5/2}$$

peor caso en $c = 1/4$


$$\frac{1}{4}^{-5/2} = 4^{-5/2} = 2^5 = 32$$

$$\text{Error} = \frac{-32}{2304} = -0,1006.$$

El signo coincide con la predicción y el valor absoluto es menor.


Interpolación con funciones a trozos.

1) Vecino más cercano.



Si x_k es la abscisa más cercana a x entonces $s(x) = y_k$.

2) Interpolación lineal



$s(x)$ es tal que en el intervalo $[x_i, x_{i+1}]$ coincide con la recta que pasa por los puntos $(x_i, y_i), (x_{i+1}, y_{i+1})$

$$s(x) = y_i \frac{(x-x_{i+1})}{x_i-x_{i+1}} + y_{i+1} \frac{(x-x_i)}{x_{i+1}-x_i} \quad \text{si } x \in [x_i, x_{i+1}]$$

a) $s(x)$ es continua $\forall x$

b) En los x_i la derivada es discontinua.


c) Error en la interpolación lineal:

$$f(x) - s(x) = \frac{f''(c)}{2} \underbrace{(x-x_i)(x-x_{i+1})}_{t(x)} \quad \text{si } x \in [x_i, x_{i+1}]$$

$\exists c \in [x_i, x_{i+1}]$

$$\text{Si } x_{i+1} - x_i = k_i$$

$$|t(x)| \leq \frac{k_i}{2} \cdot \frac{k_i}{2}$$



$$|f(x) - s(x)| \leq \frac{f''(c)}{2} \frac{k_i^2}{4}$$

$$|f(x) - s(x)| \leq \frac{\|f''\|_\infty \max k_i^2}{8}$$

$$|f(x) - s(x)| \leq \frac{\|f''\|_\infty h}{8}$$


Si tomo cada vez más puntos equiespaciados $\rightarrow h \rightarrow 0$
entonces Error $\rightarrow 0$ $\forall x$

3) { Hermite Cúbico.

Spline Cúbico.

Tienen en común : 1) En cada subintervalo $[x_i, x_{i+1}]$ la $s(x)$ coincide con un polinomio de 3º grado
2) $s(x)$ es continua y su derivada primera ($s'(x)$) es continua $\forall x$.

Supongamos que además de las ordenadas y_i conocieramos el valor de las derivadas m_i en las abscisas x_i



Con estos 4 valores construye en $[x_i, x_{i+1}]$ un polinomio
único $s(x)$ tal que $s(x_i) = y_i$

$$s(x_{i+1}) = y_{i+1}$$

$$s'(x_i) = m_i$$

$$s'(x_{i+1}) = m_{i+1}$$

queda: $s(x) = y_i + t\Delta y_i + t(t-1)(\Delta y_i - h_i m_i) + t^2(t-1)$
 $(h_i(m_i + m_{i+1}) - 2\Delta y_i)$

$$\Delta y_i = y_{i+1} - y_i ; \quad h_i = x_{i+1} - x_i$$

$$t = \frac{x - x_i}{h_i} \quad (\text{Si } x \in [x_i, x_{i+1}] \rightarrow t \in [0, 1])$$

HERMITE UNÍCICO:

- Si conozco efectivamente las derivadas m_i aplicando lo anterior consigo una interpolante $s(x)$ continua con derivada primera continua.
- si no conozco las derivadas se puede hacer previamente una estimación de las mismas

$$\begin{array}{c} y_{i-1} & & y_{i+1} \\ \cdot & y_i \\ \cdot & \vdots \end{array}$$

$$x_{i-1} \quad x_i \quad x_{i+1}$$

estimo la derivada en x_i ($i=1, \dots, n-1$)

$$\text{con } m_i = \frac{y_{i+1} - y_{i-1}}{x_{i+1} - x_{i-1}} \text{ o bien}$$

$$\frac{x_{i+1} - x_{i-1}}{2}$$

$$m_i = \frac{1}{2} \left(\frac{y_{i+1} - y_i}{x_{i+1} - x_i} + \frac{y_i - y_{i-1}}{x_i - x_{i-1}} \right)$$

$$m_0 = \frac{y_1 - y_0}{x_1 - x_0} ; \quad m_n = \frac{y_n - y_{n-1}}{x_n - x_{n-1}}$$

Error de interpolación.

a) Interpolación polinómica.

$$f(x) - P_n(x) = \frac{f^{(n+1)}(c)}{(n+1)!} (x-x_0)(x-x_1)\dots(x-x_n)$$

$c \in$ al menor intervalo que contiene a x, x_0, \dots, x_n .

b) Hermite cúbico

Si $x \in [x_i, x_{i+1}]$ $f(x)$ se approxima por un polinomio cúbico tal que coinciden ordenadas en x_i, x_{i+1} y de las derivadas primeras ($m_i = f'(x_i)$)

Por "analogía" (lo miramos como 2 puntos en x_i y 2 puntos en x_{i+1})

$$f(x) - S_i(x) = \frac{f^{(IV)}(c)}{4!} (x-x_i)^2 (x-x_{i+1})^2 \quad c \in [x_i, x_{i+1}]$$

se acota por
 $\left(\frac{h_i}{2}\right)^2 \left(\frac{h_i}{2}\right)^2$

$$|\text{Error}| \leq \frac{f^{(IV)}(c)}{4!} \frac{h_i^4}{16}$$

$$|\text{Error Hermite Cúbico}| \leq \|f^{(IV)}\|_{\infty, [x_i, x_{i+1}]} h_i^4$$

384.

interp. lineal: $|E| \leq \|f''\|_{\infty} h^2$

c) Spline cúbico:

Para el caso not a knot:

$$|\text{Error Spline}| \leq \frac{5}{384} \|f^{(IV)}\|_{\infty} h^4 \text{ en } [x_0, x_n]$$

- fórmula aproximada
- x_i equiespaciados

Interpolación de Hermite.

Es un método de interpolación polinómica, cuando tenemos para ciertas abscisas x_i , información del valor funcional y de sus derivadas

Hermite mostró una forma de construir este polinomio interpolador generalizando el esquema de diferencias divididas de Newton.

$$\text{Ejemplo: } f(x) = x^8 + 1$$

Supongamos las abscisas $x_0 = -1, x_1 = 0, x_2 = 1$.
en las cuales tenemos los valores: f, f', f''

	-1	0	1
f	2	1	2
f'	-8	0	8
f''	56	0	56

$$\text{Hermite: } f[\underbrace{x_i x_i \dots x_i}_{k \text{ veces}}] = \frac{f^{(k-1)}(x_i)}{(k-1)!}$$

$$f[x_i x_i] = f'(x_i); \quad f[x_i x_i x_i] = \frac{f''(x_i)}{2}$$

x_i	f_i	Dif de orden	Dif de 2º orden						
-1	2	-8							
-1	2	-8	28	-21					
-1	2	-1	7	-6	15	-10			
0	1	0	1	-1	5	-2	4	-1	
0	1	0	0	1	1	-2	2	1	1
0	1	1	1	6	5	10	4		
1	2	8	7	21	15				
1	2	8	28						
1	2								

Polinomio interpolador:

$$\begin{aligned}
 P_8(x) = & 2 + (-8)(x+1) + 28(x+1)^2 - 2(x+1)^3 \\
 & + 15(x+1)^3 x - 10(x+1)^3 x^2 + 4(x+1)^3 x^3 \\
 & + (-1)(x+1)^3 x^3 (x-1) + ((x+1)^3 x^3 (x-1)^2 \\
 = & x^8 + 1
 \end{aligned}$$

CURVAS DE BEZIER.

1) Polinomios de Bernstein

de grado n son una base de P_n (E.N. de los

$$1 = 1^n = (t+1-t)^n = \sum_{k=0}^{k=n} \underbrace{C_k t^k (1-t)^{n-k}}_{B_{k,n}(t)} \text{ polinomios de grado } \leq n.$$

El conjunto $\{B_{k,n}, 0 \leq k \leq n\}$.

es un conjunto de $n+1$ polinomios de grado n

Se puede probar que son LI \rightarrow son una base de P_n .

$$n=1 \quad \{1-t, t\}.$$

$$n=2 \quad \{(1-t)^2, 2t(1-t), t^2\}.$$

$$n=3 \quad \{(1-t)^3, 3(1-t)^2t, 3(1-t)t^2, t^3\}$$

Prop: a) $B_{k,n}(t) \geq 0$ si $t \in [0,1]$

$$B_{k,n}(t) \leq 1$$

b) La suma de los polinomios vale 1.

21/11

Polinomios de Bernstein.


$$B_{k,n}(t) = C_k^n t^k (1-t)^{n-k} \quad k=0,1,2,\dots,n$$

Curvas de Bezier.

1) Lineal : Si P_0 y P_1 son dos puntos (en principio del plano)

$$B(t) = (1-t)P_0 + tP_1 \quad t \in [0,1]$$

Es el segmento de P_0 a P_1



2) Cuadrático : P_0, P_1, P_2

$$B(t) = (1-t)^2 P_0 + 2t(1-t)P_1 + (1-t)^2 P_2$$

$$t=0 \rightarrow P_0$$

$$t=1 \rightarrow P_2$$

$$\left. \frac{dB}{dt} \right|_{t=0} = 2(1-t)(-1)P_0 + 2(1-2t)P_1 + 2tP_2 \Big|_{t=0} \\ = 2P_1 - 2P_0 = 2(P_1 - P_0)$$

$$\left. \frac{dB}{dt} \right|_{t=1} = 2P_2 - 2P_1 = 2(P_2 - P_1)$$

$$B(t) \in \Delta P_0, P_1, P_2$$


$$B(t) = (1-t) \underbrace{[(1-t)P_0 + tP_1]}_{\Phi_0} + t \underbrace{[(1-t)P_1 + tP_2]}_{\Phi_1} P_2$$



Q_0 : Bezier lineal entre P_0 y P_1

Q_1 : " " " " P_1 y P_2

$B(t)$



Orden n :

Tenemos $n+1$ puntos $P_0, P_1, P_2, \dots, P_n$


$$B(t) = B_{0,n}(t)P_0 + B_{1,n}(t)P_1 + \dots + B_{n,n}(t)P_n.$$

$$B_{k,n} = C_k^n t^k (1-t)^{n-k} \quad t \in [0,1]$$

$B(0) = P_0 \quad B'(0)$ colineal $P_1 - P_0$

$B(1) = P_n \quad B'(1)$ " $P_n - P_{n-1}$

$B(t) \in \alpha$ la envolvente convexa de los puntos



$$B(t) = B_{B,P_1 \dots P_n}(t) = (1-t)B_{B,P_1 \dots P_{n-1}}(t) + tB_{P_n,P_{n-1}, \dots, P_1}(t)$$

La curva de Bezier de orden n es una interpolación lineal. Bezier de grado 1) de 2 curvas de Bezier de orden $n-1$.

Examen dic. 2007.

1) Dado el sistema $x + 2y - 2z = 0$
 $x + y + z = 0$
 $2x + 2y + z = 1$

i) Plantee el método de Jacobi para resolver el sistema en forma iterativa. Haga 3 iteraciones partiendo del punto $(3, 2, 1)$

$$\begin{aligned}x &= -2y + 2z + 2 & x^{(k+1)} &= -2y^{(k)} + 2z^{(k)} + 2 \\y &= -x - z & y^{(k+1)} &= -x^{(k)} - z^{(k)} \\z &= -2x - 2y + 1 & z^{(k+1)} &= -2x^{(k)} - 2y^{(k)} + 1\end{aligned}$$

$$\hat{x}^{(0)} = \begin{pmatrix} 3 \\ 2 \\ 1 \end{pmatrix} \rightarrow \hat{x}^{(1)} = \begin{pmatrix} 0 \\ -4 \\ -9 \end{pmatrix} \rightarrow \hat{x}^{(2)} = \begin{pmatrix} -8 \\ 9 \\ 9 \end{pmatrix} \rightarrow \hat{x}^{(3)} = \begin{pmatrix} 2 \\ -1 \\ -1 \end{pmatrix}$$

exactas.

ii) Hallar la matriz de iteración J . del método de Jacobi
Calcular radio espectral y probar convergencia

$$Ax = b \quad A = M + N$$

$$\begin{aligned}Mx + Nx &= b \\Mx &= -Nx + b \rightarrow Mx^{(k+1)} = -Nx^{(k)} + b \\x &= \underbrace{M^{-1}Nx}_{B} + \underbrace{M^{-1}b}_{f} \rightarrow x^{(k+1)} = Bx^{(k)} + f.\end{aligned}$$

$$J = \begin{bmatrix} 0 & -2 & 2 \\ -1 & 0 & -1 \\ -2 & -2 & 0 \end{bmatrix} \quad \chi_J(\lambda) = \det(J - \lambda I) = \begin{vmatrix} -\lambda & -2 & -2 \\ -1 & -\lambda & -1 \\ -2 & -2 & -\lambda \end{vmatrix}$$
$$-\lambda^3 + 4 - 4 - (4\lambda - 2\lambda - 2\lambda) = -\lambda^3.$$

$\lambda = 0$ triple, radio espectral $= 0 < 1 \rightarrow$ el método converge.

iii) Idem con Gauss-Seidel

$$\begin{aligned}x &= -2y + 2z + 2 \\x + y &= -z \\2x + 2y + z &= 1.\end{aligned}$$

$$\begin{aligned}x^{(k+1)} &= -2y^{(k)} + 2z^{(k)} + 2 \\x^{(k+1)} + y^{(k+1)} &= -z^{(k)} \\2x^{(k+1)} + 2y^{(k+1)} + z^{(k+1)} &= 1.\end{aligned}$$

$$\begin{aligned}x^{(k+1)} &= -2y^{(k)} + 2z^{(k)} + 2 \\y^{(k+1)} &= -x^{(k+1)} - z^{(k)} \\z^{(k+1)} &= -2x^{(k+1)} - 2y^{(k+1)} + 1\end{aligned}$$

$$\begin{aligned}x' &= -2y + 2z + 2 \\y' &= -x' - z \\z' &= -2x' - 2y' + 1\end{aligned}$$

Vamos a hallar los x', y', z'
en función de x, y, z

$$y' = -x' - z = 2y - 2z - 2 - z = 2y - 3z - 2.$$

$$z' = -2x' - 2y' + 1 = -2(-2y + 2z + 2) - 2(2y - 3z - 2) + 1 = 2z + 1$$

$$-\begin{pmatrix} x' \\ y' \\ z' \end{pmatrix} = \begin{pmatrix} 0 & -2 & 2 \\ 0 & 2 & -3 \\ 0 & 0 & 2 \end{pmatrix} \begin{pmatrix} x \\ y \\ z \end{pmatrix} + \begin{pmatrix} 2 \\ -2 \\ 1 \end{pmatrix}$$

$$\lambda_G(\lambda) = \begin{vmatrix} -\lambda & -2 & 2 \\ 0 & 2-\lambda & -3 \\ 0 & 0 & 2-\lambda \end{vmatrix} = -\lambda(2-\lambda)(2-\lambda)$$

valores propios
0 simple
2 doble.

$$\Re(G) = 2 \geq 1 \text{ no}$$

converge.

i) Escriba el método de sobrerelajación (SOR)

para $\omega = 3/2$ está la convergencia garantizada

$$Ax = b.$$

$$\omega Ax = \omega b$$

$$\omega A = \begin{bmatrix} \omega_{11} & \omega_{12} & \omega_{13} \\ \omega_{21} & \omega_{22} & \omega_{23} \\ \omega_{31} & \omega_{32} & \omega_{33} \end{bmatrix} =$$

$$M(\omega) = \begin{bmatrix} a_{11} & 0 & 0 \\ w_{121} & a_{22} & 0 \\ w_{131} & w_{132} & a_{33} \end{bmatrix} + \begin{bmatrix} (\omega-1)a_{11} & w_{112} & w_{113} \\ 0 & (\omega-1)a_{22} & w_{123} \\ 0 & 0 & (\omega-1)a_{33} \end{bmatrix}$$

Si $\omega = 3/2$:

$$\begin{pmatrix} 1 & 0 & 0 \\ 3/2 & 1 & 0 \\ 3 & 3 & 1 \end{pmatrix} \begin{pmatrix} x^{(k+1)} \\ y^{(k+1)} \\ z^{(k+1)} \end{pmatrix} = \begin{pmatrix} -1/2 & -3 & 3 \\ 0 & -1/2 & -3/2 \\ 0 & 0 & -1/2 \end{pmatrix} \begin{pmatrix} x^{(k)} \\ y^{(k)} \\ z^{(k)} \end{pmatrix} + \begin{pmatrix} 3 \\ 0 \\ 3/2 \end{pmatrix}$$

$$x' = -1/2x - 3y + 3z + 3$$

$$y' = -3/2x' - 1/2y - 3/2z$$

$$z' = -3x' - 3y' - 1/2z + 3/2$$

$$x' = -1/2x - 3y + 3z + 3$$

$$\text{Resuelta: } y' = 3/4x + 4y - 6z - 9/2$$

$$z' = -3/4x - 3y + 17/2z + 6$$

$$B_{SOR} = \begin{pmatrix} -1/2 & -3 & 3 \\ 3/4 & 4 & -6 \\ -3/4 & -3 & 17/2 \end{pmatrix}$$

Sugerencia: $\text{tr}A_2\alpha = \text{suma valores propios}$

$$\text{tr}A_2\alpha = 12 \quad \lambda_1 + \lambda_2 + \lambda_3 = 12$$

$$\Re(B_{SOR}) > 1 \rightarrow \text{no converge}$$

